Gestion conjointe du bloc opératoire, des lits et de l'ambulatoire : une approche hybride par métaheuristiques et patients fantômes

Centrale Lille — projet « IA et santé » 2026

Version 7.0 — 20 octobre 2026

Table des matières

1 Résumé **2**

2 Introduction **2**

3 Revue de la littérature **3**
3.1 Planification du bloc et ressources d'aval . . . 3
3.2 Méthodes de résolution . . . 3
3.3 Prévision des durées . . . 3
3.4 Positionnement . . . 3

4 Le problème et les données **3**
4.1 Ressources considérées . . . 4
4.2 Ce que montrent les données . . . 4
4.3 Hypothèses et paramètres . . . 5
4.4 Contraintes opérationnelles . . . 6

5 Notre approche du problème **6**
5.1 Trois niveaux de décision . . . 6
5.2 Le modèle mathématique, niveau par niveau . . . 7
5.3 Prévoir à la consultation : durées et séjours . . . 9
5.4 Les patients fantômes . . . 10

6 Résolution : des trois études à la chaîne hybride **12**
6.1 Trois études, trois points de vue . . . 12
6.2 Approche hybride . . . 16
6.3 Face aux aléas . . . 18

7 Expérimentations et résultats **21**
7.1 Protocole et indicateurs . . . 21
7.2 La chaîne hybride face aux trois études . . . 21
7.3 Pas à pas : ce qu'apporte chaque brique . . . 22
7.4 Toutes les combinaisons . . . 24
7.5 Sensibilité : réglages, vacances, surcharge . . . 24
7.6 Les aléas connus à l'avance . . . 26
7.7 Limites . . . 26

8 Mise en œuvre à l'hôpital **27**
8.1 L'interface . . . 27
8.2 Le cadre réglementaire, et comment l'outil s'y conforme . . . 30

9 Conclusion **32**

1 Résumé

Dans l'établissement de chirurgie orthopédique étudié, le bloc opératoire, les lits d'hospitalisation et l'unité de chirurgie ambulatoire sont planifiés séparément, alors que chaque opération mobilise les trois. À partir de ses données anonymisées (14 649 interventions de 2019 à 2022), nous avons construit un outil qui coordonne trois décisions : la grille des vacations des chirurgiens, la date proposée au patient en consultation et l'ordre de passage fixé la veille. Trois études ont d'abord été menées en parallèle, chacune avec une métaheuristique (recherche tabou, algorithme génétique, recuit simulé) pour construire la grille et ordonner la journée ; rejouées sur les mêmes patients, elles ont chacune un point fort et un prix. La chaîne hybride reprend le meilleur choix de chaque étude, corrige son prix et ajoute des *patients fantômes*, une prévision de la demande encore à venir. Un modèle d'apprentissage prévoit à la consultation la durée et le nombre de nuits ; un système multi-agents et un moteur de reprogrammation gèrent les aléas. Sur les patients de mai à décembre 2022, urgences comprises et à heures de bloc constantes, la chaîne divise par 3,4 la variance des lits occupés les nuits de semaine hors vacances par rapport à la pratique simulée (de 11,4 à 3,4), ramène le pic de 21 à 17 lits et le délai qui couvre 90 % des patients de 115 à 51 jours, sans laisser de patient sans date. Le jour de l'opération, le système multi-agents opère 99 % des urgences dans leur délai, contre 87 % sans agents, et divise par 3,6 leur attente. Une interface web met l'outil à la disposition des équipes.

÷ 3,4	**21 → 17**	**115 → 51 j**	**99 %**
variance des lits, nuits de semaine hors vacances	lits au pic, à heures de bloc égales	délai pour opérer 90 % des patients	urgences opérées dans leur délai (87 % sans agents)

2 Introduction

Le bloc opératoire est l'un des postes les plus coûteux d'un hôpital, et il commande l'activité des services situés en aval. Selon le patient, chaque intervention programmée mobilise soit une place en unité de chirurgie ambulatoire (UCA) pour la journée, soit un lit d'hospitalisation pour une ou plusieurs nuits. Pourtant, la programmation se fait chirurgien par chirurgien, sans vue sur ces ressources. Dans l'établissement étudié, un service d'orthopédie, l'occupation des lits monte de 8 lits la nuit du dimanche à 15 la nuit du mercredi, et varie du simple au triple d'une nuit à l'autre. Les pics obligent à dimensionner le personnel pour le pire, les creux le laissent inoccupé.

La question. Peut-on coordonner le bloc, les lits et l'ambulatoire *sans ajouter d'heures de bloc*, en jouant seulement sur la répartition des vacations entre chirurgiens, sur la date donnée à chaque patient et sur l'ordre de passage ?

Trois difficultés rendent le problème délicat. Les trois décisions sont prises à des moments différents, de l'année à la veille de l'opération, et dépendent l'une de l'autre. La date est donnée en consultation, sans connaître les patients des semaines suivantes, et ne bouge plus ensuite. Enfin, le planning subit des aléas : urgences, annulations, absences, pannes, durées réelles différentes des durées prévues.

Le cheminement du rapport. Chaque partie répond à une question posée par la précédente (figure 1). Les données montrent *ce qu'il faut lisser* et *ce qui est prévisible* (section 4) ; cela conduit à découper le problème en trois niveaux, à écrire le modèle mathématique de chacun, fondement de toute la suite, et à prévoir ce qui n'est pas encore connu : les durées, les séjours et les patients à venir (section 5). Les trois études du groupe isolent chacune un point fort ; la chaîne hybride assemble ces points forts et ajoute de quoi réagir aux aléas (section 6). Les résultats valident ensuite chaque choix pas à pas, puis le jour J, la sensibilité et les aléas connus à l'avance (section 7). La section 8 montre comment l'outil s'insère à l'hôpital, et la conclusion distingue ce qui est démontré de ce qui reste un choix de l'établissement.

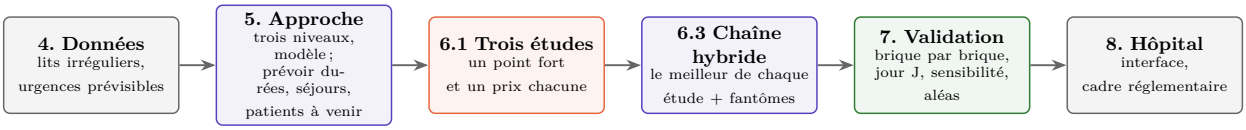


Figure 1 – Le fil conducteur du rapport : chaque partie répond à la question laissée par la précédente.

3 Revue de la littérature

3.1 Planification du bloc et ressources d'aval

La planification des blocs opératoires a fait l'objet de nombreuses revues [1]. Elles distinguent un niveau tactique, la grille des vacations, et un niveau opérationnel, la date et l'ordre des interventions, lui-même hors ligne ou en ligne. Le lien avec les lits a d'abord été traité au niveau tactique : des grilles cycliques sont construites pour niveler l'occupation des lits qui en résulte [2], puis pour plusieurs unités d'aval à la fois [3]. Ces travaux supposent la demande connue ou stationnaire. La date en ligne relève d'une autre famille, par exemple la programmation dynamique des patients selon leur priorité [4].

3.2 Méthodes de résolution

Les approches exactes passent difficilement à l'échelle d'une année et de plusieurs niveaux de décision. Les métaheuristiques, recuit simulé [5], recherche tabou [6] et algorithmes génétiques [7], ont été appliquées à des cas hospitaliers réels [8], et on les combine souvent : une méthode explore, une autre affine. Pour réagir aux aléas, des systèmes multi-agents ont été proposés pour la programmation des patients [9].

3.3 Prévision des durées

Toute programmation repose sur des durées estimées. Les durées opératoires suivent des lois asymétriques, et les modèles d'apprentissage améliorent leur prévision [10].

3.4 Positionnement

À notre connaissance, aucun travail ne traite à la fois la grille, la date en ligne, l'ordre de la journée et les aléas, avec les lits et l'ambulatoire dans l'objectif (tableau 1). Notre règle de date se distingue surtout par une prévision explicite de la demande à venir, sous forme de patients fictifs.

Tableau 1 – Positionnement. G : grille ; D : date des patients ; J : ordre de la journée ; A : aléas en temps réel ; L : lits ou unités d'aval dans l'objectif.

Référence	G	D	J	A	L	Approche
[2]	×				×	grille cyclique qui nivelle les lits
[3]	×				×	grille et plusieurs unités d'aval
[4]		×				programmation dynamique, en ligne
[8]		×	×			algorithme génétique, hôpital réel
[9]		×		×		agents
Ce travail	×	×	×	×	×	métaheuristiques hybrides, patients fantômes, agents

4 Le problème et les données

Ce que cette partie établit. Ce qu'il faut lisser (les lits des nuits de semaine), ce qui est prévisible (les urgences) et ce qui ne l'est pas encore (la durée et le séjour de chaque patient).

L'établissement opère dans quatre salles et suit ses patients dans un service d'hospitalisation et une unité de chirurgie ambulatoire. Le temps de bloc est découpé en *vacations* : une vacation est une demi-journée d'une salle attribuée à un chirurgien, qui y opère ses propres patients. Il s'agit de répartir ces vacations, de dater les patients et d'ordonner chaque journée de façon que l'occupation des lits et de l'ambulatoire soit régulière, sans ajouter d'heures de bloc.

4.1 Ressources considérées

Tableau 2 – Les trois ressources gérées ensemble.

	Bloc opératoire	Lits d'hospitalisation	Unité ambulatoire
Patients concernés	tous	ceux qui restent au moins une nuit	ceux qui sortent le soir même
Unité de mesure	minutes de vacation	lits occupés chaque nuit	admissions par jour
Capacité retenue	4 salles, 144 h par semaine	42 lits au maximum	18 admissions par jour
Ce qui la fait varier	la grille des vacations	le jour de l'opération et la durée du séjour	le jour de l'opération

Dix-huit chirurgiens, anonymisés C1 à C18, se partagent les quatre salles, numérotées de 2 à 5, le matin de 8 h à 13 h et l'après-midi de 13 h 30 à 17 h 30. Des créneaux de deux heures, 7,4 heures par semaine au total, sont réservés aux urgences. Deux flux de patients arrivent au bloc. Les patients *programmés* sont vus en consultation et reçoivent une date à l'avance : ce sont eux que l'outil planifie. Les *urgences* arrivent sans rendez-vous et doivent être opérées dans les 24 ou 72 heures selon leur gravité.

4.2 Ce que montrent les données

La base compte 14 649 interventions de janvier 2019 à décembre 2022, dont 14 477 avec des heures de salle, avec pour chacune les dates d'entrée, d'opération et de sortie, les heures de salle, les codes d'actes et de diagnostics et le chirurgien. Deux défauts ont été corrigés : la durée de séjour déclarée contredit les dates dans 17,5 % des cas, et le nombre de nuits est donc recalculé à partir des dates ; le premier code d'acte est souvent un examen, et l'acte retenu est le premier code chirurgical. Les périodes de Covid sont exclues des moyennes.

Les lits à lisser. En 2022, les lits occupés vont de 0 à 24 d'une nuit à l'autre (figure 2). Ils montent jusqu'au milieu de la semaine, 15 lits en moyenne les nuits de mercredi et de jeudi, et retombent à 8 ou 9 le week-end : les patients opérés en début de semaine sont sortis avant le samedi, ceux du jeudi et du vendredi occupent le week-end. Pendant les vacances scolaires, l'activité programmée baisse d'un tiers et les lits avec elle.

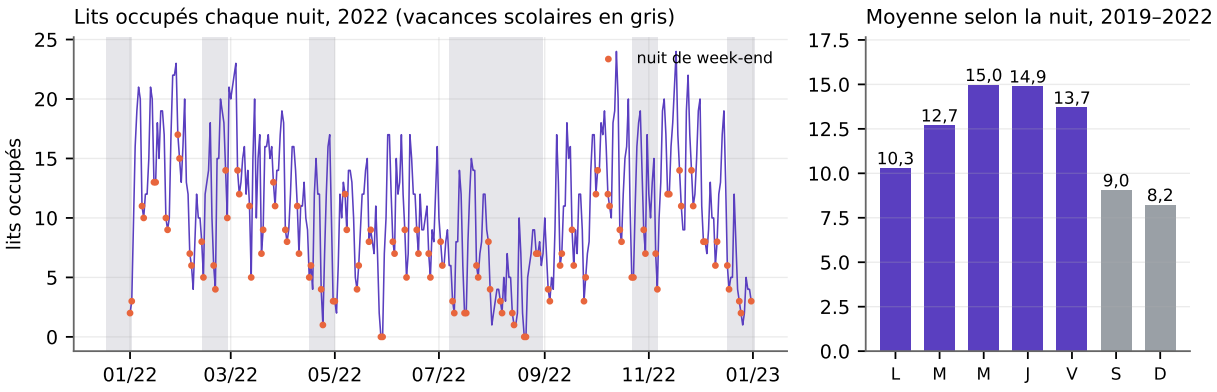


Figure 2 – Les lits occupés, séjours réels. À gauche, chaque nuit de 2022 ; à droite, la moyenne selon la nuit de la semaine, 2019–2022 hors Covid.

Ce constat fixe la mesure de tout le rapport. Le service veut des *nuits de semaine régulières*, et des week-ends et vacances *plus creux*, où le personnel manque. Le critère principal est donc la **variance des lits occupés les nuits du lundi au vendredi, hors vacances scolaires, ponts et jours fériés** : c'est la régularité que le service demande. Mesurée vacances comprises, elle pénaliserait une méthode qui allège volontairement les vacances ; le respect de la consigne du week-end et des vacances est donc mesuré à part, par le rapport entre les lits de ces nuits et ceux des nuits de semaine. Pour l'hôpital réel, sur mai–décembre 2022, cette variance vaut 20,1.

Les urgences : fréquentes et prévisibles. La base ne signale pas les urgences. Nous les repérons par le diagnostic principal, avec la classification de priorité chirurgicale de la FSSA britannique : classe U1, à opérer dans les 24 heures, et U2, dans les 72 heures. Elles représentent 7 % de l'activité, 253 interventions en 2022, dont 28 U1, et quatre constats les rendent planifiables (figure 3).

1. *Un rythme stable* : 4,5 urgences par semaine de 2019 à 2022, sans saison marquée.
2. *Une loi connue* : le nombre d'urgences d'une semaine suit une loi de Poisson ; sa variance est égale à sa moyenne (rapport 1,03 sur 165 semaines). On ne sait pas quelle semaine sera chargée, mais on connaît la probabilité de chaque niveau : 9 semaines sur 10 demandent moins de 9 heures de bloc. C'est ce qui permet de dimensionner une réserve et de prévoir des fantômes d'urgence.
3. *Presque toujours en semaine* : 92 % sont opérées un jour ouvré ; les U1 sont rares, ce qui laisse en général un ou deux jours pour trouver une salle.
4. *Peu de baisse en vacances* : par jour ouvré, les urgences ne baissent que de 4 % pendant les vacances (0,89 à 0,85 par jour), contre 36 % pour l'activité programmée (15,1 à 9,7) : la réserve d'urgence doit être gardée toute l'année.

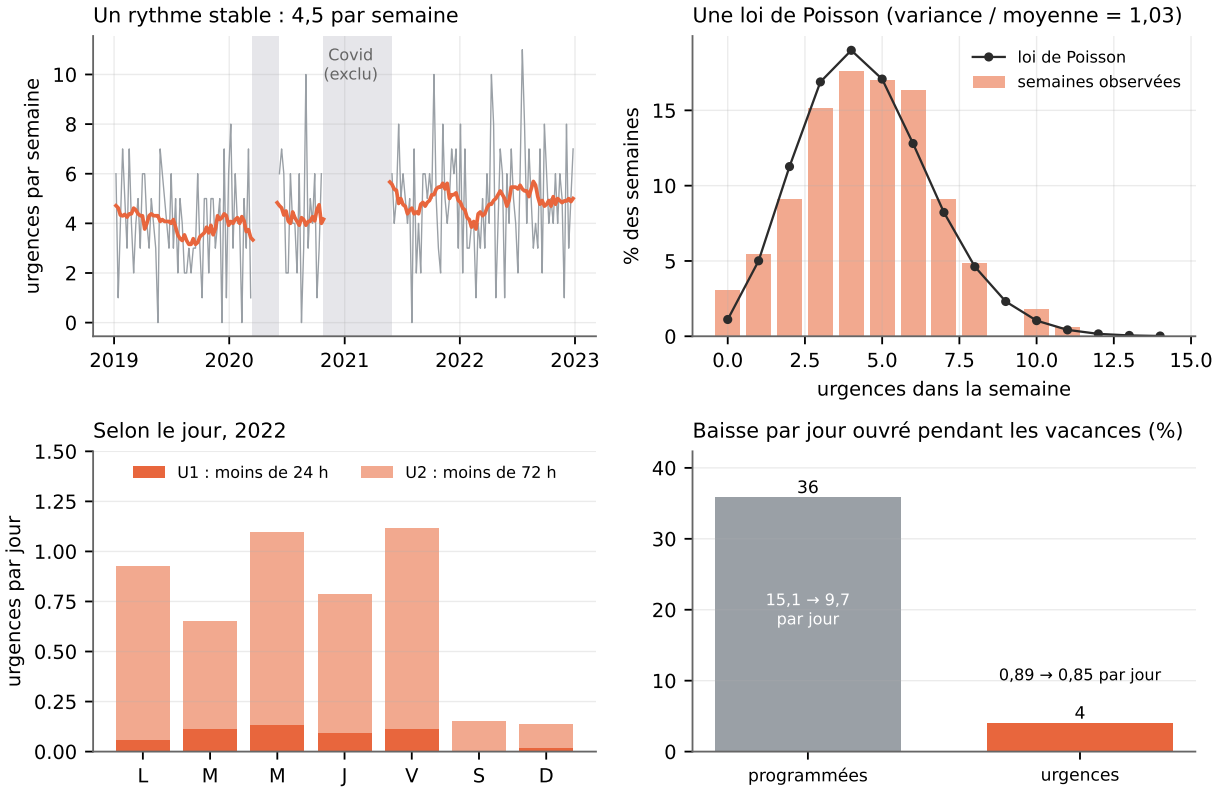


Figure 3 – Les urgences, 2019–2022. En haut, nombre par semaine (gris) et moyenne sur trois mois, puis semaines observées et loi de Poisson de même moyenne ; en bas, répartition selon le jour en 2022, et baisse par jour ouvré pendant les vacances (jours fériés et ponts exclus).

La troisième donnée dont le planning a besoin, la durée des interventions, n'est pas connue à la consultation : elle est étudiée avec sa prévision (section 5.3).

4.3 Hypothèses et paramètres

Le chirurgien d'un patient programmé ne change jamais. La durée d'une intervention est estimée par la médiane des durées passées du même acte, avec une marge (90e centile moins médiane). Pour comparer les méthodes, le nombre de nuits est d'abord supposé connu ; la section 7.3 lève cette hypothèse. La base ne contient pas la date de consultation : nous la plaçons 30 jours avant la date réelle de l'opération, ce qui garde l'ordre réel de la demande. Les urgences sont séparées du flux programmé : elles ne passent pas par la règle de date, et leurs lits s'ajoutent toujours à ceux des patients programmés. Le tableau 3 donne les autres paramètres.

Tableau 3 – Paramètres du modèle et leur origine.

Paramètre	Valeur	Origine
Salles, horaires, créneaux d'urgence	144 h et 7,4 h par semaine	grille de l'hôpital
Durées, nuits, dates, chirurgiens	—	base de l'hôpital, 2019–2022
Urgences	253 en 2022	repérées par le diagnostic principal
Délais avant l'opération	7 jours à 6 mois	minimum légal de 3 jours ; consigne du projet
Temps entre deux patients	15 min	hypothèse du groupe
Lits ; admissions ambulatoires	42 ; 18 par jour	hypothèse ; calée sur 2022
Ouverture de l'unité ambulatoire	7 h 30 – 20 h	hypothèse du groupe
Date de consultation	30 jours avant l'opération	reconstruite, absente de la base
Réserve pour les urgences	5 % du temps, 2 lits, 2 admissions	testée de 0 à 15 % (section 7.5)
Cible du week-end et des vacances	70 % et 65 % de la semaine	choix du service (section 7.5)
Lits en vacances, ponts et fériés	12 pour le programmé	moins de personnel post-opératoire

4.4 Contraintes opérationnelles

- Une vacation ne déborde pas, marges comprises, et l'unité ambulatoire ferme à 20 h.
- Une vacation attribue une salle à un seul chirurgien, et un chirurgien n'a jamais deux salles en même temps ; un patient est opéré par son chirurgien, dans la salle de sa vacation, entre 7 jours et 6 mois après sa consultation.
- Lits et admissions ambulatoires restent sous leur capacité, réserve d'urgence déduite ; en vacances, au plus 12 lits pour le programmé.
- Chaque chirurgien garde entre 75 % et 150 % de son volume actuel de vacations, et une semaine type régulière : au plus une journée d'écart entre semaine paire et semaine impaire.
- Les créneaux d'urgence restent réservés aux urgences.

À retenir

Il faut rendre régulières les nuits de semaine hors vacances, et laisser le week-end et les vacances plus creux. Les urgences, elles, sont prévisibles en moyenne. Reste à savoir *quand* décider, et avec quelle information : c'est l'objet de la partie suivante.

5 Notre approche du problème

Ce que cette partie établit. Les décisions sont prises à trois moments différents ; à chacun, il manque une information. Nous découpons donc le problème en trois niveaux, nous écrivons le modèle mathématique de chacun (section 5.2), puis nous prévoyons ce qui manque : la durée et le séjour du patient (section 5.3), puis les patients encore à venir (section 5.4).

5.1 Trois niveaux de décision

Les décisions ne sont prises ni au même moment ni avec la même information. Nous les traitons en trois niveaux, qui suivent l'organisation réelle du bloc (figure 4) : chaque niveau fixe le cadre du suivant.

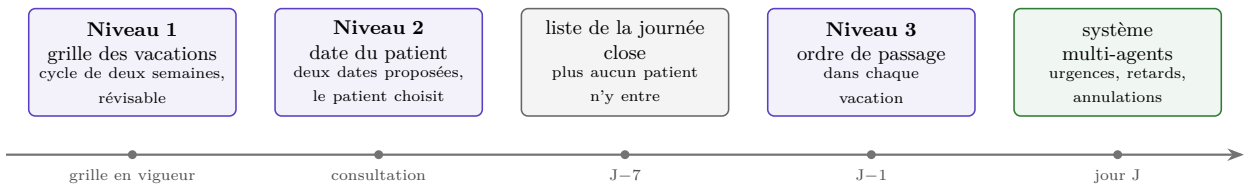


Figure 4 – Les trois niveaux de décision dans le temps. Le système multi-agents prend le relais le jour de l'opération.

Niveau 1 : la grille des vacations. Elle dit quel chirurgien occupe chaque demi-journée de chaque salle. Elle suit un cycle de deux semaines, semaine paire et semaine impaire : chaque chirurgien retrouve la même semaine type, à une journée près. Elle est recalculée en quelques minutes si un chirurgien demande une modification. C'est à ce niveau que se joue l'essentiel du lissage : placer sur des jours différents les chirurgiens dont les patients restent longtemps hospitalisés.

Niveau 2 : la date du patient. À la sortie de la consultation, le logiciel cherche la première date possible dans les vacations du chirurgien, puis regarde les dates des 14 jours suivants : c'est la *fenêtre de tolérance*. Il évalue l'effet de chaque date sur les lits, propose les deux meilleures, et le patient choisit. Un patient n'attend donc jamais plus de deux semaines au-delà de sa première date possible. La date est définitive.

Niveau 3 : l'ordre de la journée. Sept jours avant, la liste d'une journée est close. La veille, le logiciel fixe l'ordre de passage dans chaque vacation : le chirurgien n'a qu'une salle, et seul l'ordre de ses patients reste à décider. L'ordre fixe les heures d'arrivée en ambulatoire, donc les places occupées en même temps. Le jour J, un système multi-agents ajuste ce plan face aux aléas (section 6.3).

Chaque niveau a ses décisions, son coût et ses contraintes : la section suivante les écrit.

5.2 Le modèle mathématique, niveau par niveau

Ce modèle est le fondement de tout le rapport : chaque méthode qui suit, des trois études à la chaîne hybride, cherche à le résoudre, et chaque résultat se lit dans ses termes. Le problème complet, sur une année et trois niveaux, est trop grand pour être résolu d'un bloc : nous le formulons niveau par niveau, chaque niveau fixant les données du suivant.

Tableau 4 – Notations.

$m \in M$; $p \in P$, $m(p)$	chirurgiens ; patients et leur chirurgien
$k \in \{\text{paire}, \text{impaire}\}$, d, $r \in \{2, .., 5\}$, h	semaine du cycle, jour ouvré, salle, demi-journée
$v \in V$; j_v, TVO_v	vacations datées ; leur jour et leur temps offert
n ; $N_p(j)$	nuits ; nuits occupées par p s'il est opéré le jour j
d_p, μ_p ; $\theta = 15$ min	durée estimée et marge de p ; temps entre deux patients
t_p ; q_m, q_m^0	jour de consultation ; quota de demi-journées de m par cycle, quota actuel
$\bar{L}_n$; $\bar{P} = 18$	lits disponibles la nuit n (42, ou 14 en vacances, réserve comprise) ; admissions par jour
$r_L = r_P = 2$; $\tau = 0{,}05$	réserves d'urgence en lits et en admissions ; part réservée de chaque vacation

Décisions. Au niveau 1, $X_{k,d,r,h} \in M \cup \{\varnothing\}$ désigne le chirurgien qui occupe la demi-journée h de la salle r le jour d de la semaine k. Au niveau 2, $x_{p,v} = 1$ si le patient p est opéré dans la vacation v. Au niveau 3, une permutation σ_v des patients de chaque vacation v fixe leurs heures de passage : la salle est celle de la vacation. On en déduit les lits occupés la nuit n, $L_n = \sum_{p,v} x_{p,v}\, \mathbf{1}\{n \in N_p(j_v)\}$, et les admissions ambulatoires du jour j, P_j. Ici, $\mathbf{1}\{A\}$ désigne l'indicatrice de l'événement A : elle vaut 1 si A est vrai et 0 sinon.

La cible de lits. Chaque nuit reçoit une cible relative f_n : 1 en semaine, 0,70 les nuits du samedi et du dimanche, 0,65 pendant les vacances, les ponts et les fériés (les deux réductions se cumulent). On mesure l'écart des lits à la forme de cette cible, à un facteur d'échelle κ près, puisque le niveau moyen est fixé par la demande. Une simple variance pousserait au contraire à remplir le week-end et les vacances, où le personnel manque :

$$\mathcal{E}_f(L) = \min_{\kappa} \frac{1}{n} \sum_{n} (L_n - \kappa f_n)^2. \tag{1}$$

Avec $f_n = 1$ pour toutes les nuits, $\mathcal{E}_f$ est simplement la variance.

Coût de la grille. La grille est évaluée sans simuler de patients. Soit $O_{s,j}$ les minutes que le chirurgien s opère le jour j du cycle de 14 jours. Avec $\kappa_s(o)$ les lits occupés par minute opérée o jours après l'opération

et α_s les admissions ambulatoires par minute, les lits et admissions attendus sont $\Lambda_n = \sum_{s,j} \kappa_s\big((n-j) \bmod 14\big)\, O_{s,j}$ et $\Pi_j = \sum_s \alpha_s O_{s,j}$. Chaque terme est rapporté à sa valeur sur la grille actuelle :

$$F(X) = w_L\, \frac{\mathcal{E}_f(\Lambda)}{\mathcal{E}^{\text{réf}}} + \frac{\mathrm{Var}(\Pi)}{\mathrm{Var}^{\text{réf}}} + \frac{T_{\text{perdu}}}{T^{\text{réf}}} + \frac{T_{\text{délai}}}{T^{\text{réf}}} + \frac{T_{\text{salles}}}{T^{\text{réf}}} + 100\,(\Omega + I), \tag{2}$$

où T_{perdu} est le temps offert non utilisé, $T_{\text{délai}}$ l'attente due à l'espacement des jours opératoires, T_{salles} le nombre de salles ouvertes, Ω le dépassement de 40 lits ou de 16 admissions, et I l'irrégularité entre semaine paire et impaire au-delà d'une journée. Le poids des lits w_L vaut 1 ou 4 selon les candidates (section 6.2). La grille se répète toute l'année : sa cible ne contient que le week-end, et les vacances sont traitées au niveau de la date.

Coût d'une date. Les vacations candidates d'un patient sont celles de son chirurgien entre sa première date possible j_1 et $j_1 + 14$. Chacune est notée par la hausse de l'écart à la cible qu'elle provoque sur les 13 semaines suivantes W_t :

$$\Phi_p(v) = \mathcal{E}_f\big(E + \delta_v\big)_{W_t} - \mathcal{E}_f(E)_{W_t}, \tag{3}$$

où E est la courbe des lits attendus, patients déjà datés et patients fantômes (section 5.4, équation (11)), et δ_v les lits qu'ajoute le patient s'il est opéré dans v, moins les fantômes qu'il remplace. La cible suit ici le vrai calendrier.

Le niveau 2 se résout par énumération. La date est donnée patient par patient, à la consultation, et ne bouge plus : les patients déjà datés sont fixés, et ceux qui consulteront plus tard ne sont pas encore connus. À chaque consultation, la seule décision est donc de choisir une vacation parmi celles du chirurgien dans la fenêtre de 14 jours. Un chirurgien ayant au plus une salle par demi-journée, cela fait au plus 28 vacations à évaluer (14 jours, matin et après-midi), et en pratique quelques-unes. On les évalue toutes avec (3) : la meilleure date est exacte et obtenue en une fraction de milliseconde. Une métaheuristique n'aurait rien à explorer, puisqu'il n'y a ni échange ni voisinage entre des patients déjà datés. La qualité de la date dépend donc de la justesse de la courbe attendue E, c'est-à-dire des prévisions, et non d'une méthode de recherche.

Coût d'une journée. Pour un ordre de passage σ, avec les durées estimées et leurs valeurs au 90e centile (exposant 90) :

$$J(\sigma) = 10^7\,\mathrm{dep} + 10^5\, n_{\text{reportés}} + 2000\, n_{\text{UCA>20h}} + 3\,\mathrm{dep}^{90} + 150\, n^{90}_{\text{UCA>20h}} + 15\,\mathrm{pic} + 30\,\sigma_{\text{places}} + \mathrm{creux}, \tag{4}$$

où dep est le dépassement des vacations, pic et σ_{places} le pic et l'écart-type des places ambulatoires occupées et creux le temps non utilisé. Les poids hiérarchisent les objectifs : la faisabilité d'abord, le confort de l'ambulatoire ensuite.

Contraintes.

$$\textstyle\sum_{k,d,r,h} \mathbf{1}\{X_{k,d,r,h} = m\} = q_m, \qquad 0{,}75\, q^0_m \le q_m \le 1{,}5\, q^0_m, \qquad \sum_m q_m = 64 \tag{5}$$

$$\Big|\textstyle\sum_{d,r,h} \mathbf{1}\{X_{\text{paire},d,r,h} = m\} - \sum_{d,r,h} \mathbf{1}\{X_{\text{impaire},d,r,h} = m\}\Big| \le 2 \qquad \forall m \tag{6}$$

$$\textstyle\sum_r \mathbf{1}\{X_{k,d,r,h} = m\} \le 1 \qquad \forall k, d, h, m \tag{7}$$

$$\textstyle\sum_{v \in V_{m(p)}} x_{p,v} \le 1, \qquad x_{p,v} = 0 \text{ si } j_v \notin [t_p + 7,\ t_p + 182] \tag{8}$$

$$\textstyle\sum_p d_p\, x_{p,v} + \sqrt{\sum_p \mu_p^2\, x_{p,v}} + \theta\,\big(\sum_p x_{p,v} - 1\big) \le (1 - \tau)\,\mathrm{TVO}_v \qquad \forall v \tag{9}$$

$$L_n \le \bar{L}_n - r_L, \qquad P_j \le \bar{P} - r_P \tag{10}$$

Dans l'ordre : volume de chaque chirurgien ; régularité entre semaine paire et semaine impaire ; au plus une salle par chirurgien et par demi-journée ; même chirurgien et délais ; capacité d'une vacation, marges comprises ; lits et admissions, avec la capacité réduite des vacances. Les marges des patients d'une vacation se cumulent en racine de la somme des carrés : les additionner supposerait que tous les actes dérapent ensemble. Le plafond de lits des vacances garantit la capacité, là où la cible reste souple.

Où servent les métaheuristiques. Les niveaux 1 et 3, eux, sont combinatoires : la grille répartit 64 demi-journées entre 18 chirurgiens sous contraintes de volume et de régularité, et l'ordre d'une vacation de n patients a $n!$ possibilités, à décider pour chaque vacation de l'année. C'est à ces deux niveaux, et seulement à eux, que les études du groupe ont appliqué leurs métaheuristiques (section 6.1).

Le coût d'une date (3) suppose connus deux éléments que la consultation ne donne pas : le temps et le séjour du patient que l'on date, et les patients qui n'ont pas encore consulté. Les deux sections suivantes les prévoient.

5.3 Prévoir à la consultation : durées et séjours

Le temps en salle varie beaucoup (figure 5) : 70 minutes en médiane, mais une intervention sur dix dépasse 128 minutes. Il dépend d'abord du type d'intervention, de 32 minutes pour un canal carpien à plus de 100 pour une prothèse, mais aussi du chirurgien : pour une même arthroscopie du genou, la médiane va de 38 à 56 minutes. Prévue par la médiane de son acte, la durée n'est juste, à 15 minutes ou 15 % près, que pour 58 % des interventions de 2022, et 12 % dépassent la prévision de plus d'une demi-heure.

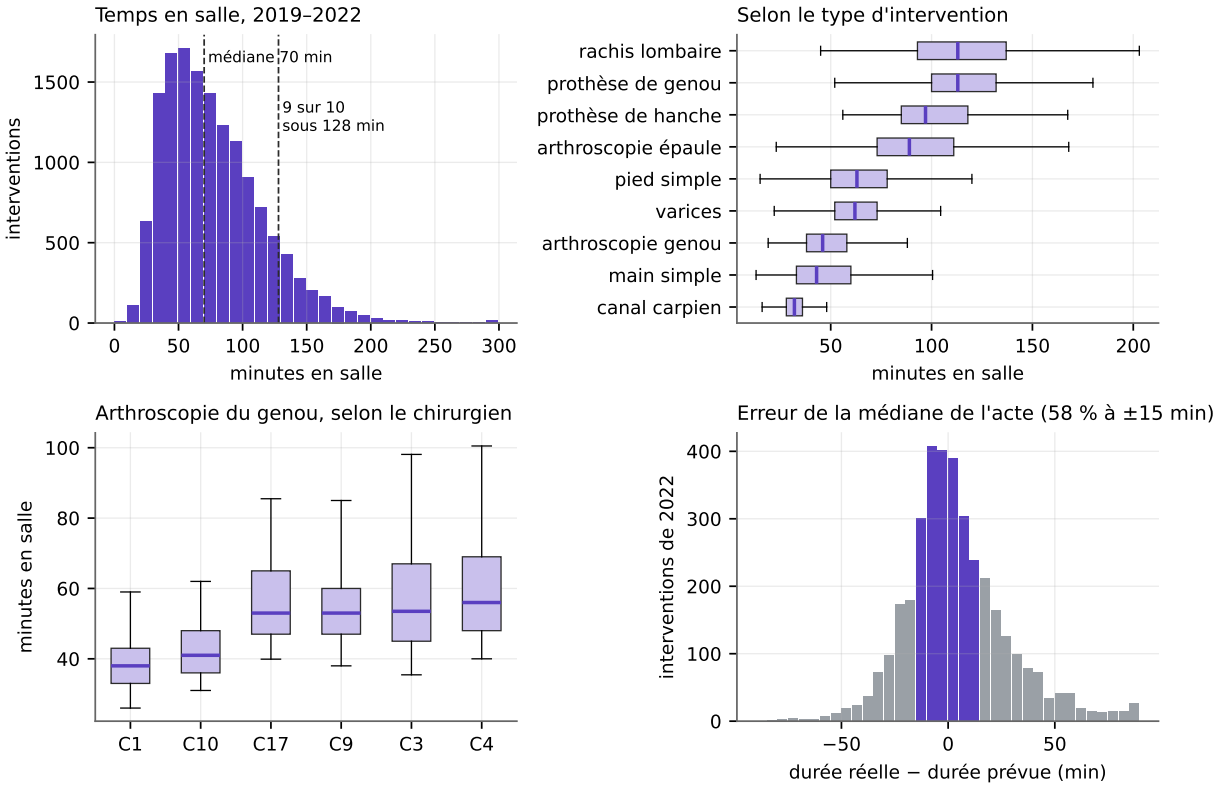


Figure 5 – Le temps en salle, 2019–2022. Boîtes : moitié centrale des interventions ; moustaches : 1,5 fois l'écart interquartile (5e et 95e centiles pour les chirurgiens). En bas à droite, erreur de la médiane de l'acte en 2022 ; en violet, moins de 15 minutes.

Nous avons donc appris un modèle de *gradient boosting* (figure 6) : 300 petits arbres de décision, chacun corrigeant l'erreur laissée par les précédents. Il n'utilise que ce qui est connu à la consultation ; un seul modèle sert tous les chirurgiens, le chirurgien étant une variable, car chacun n'a fait la moitié de ses actes qu'une ou deux fois en quatre ans. Il est appris sur 2019–2021 et testé sur 2022, une année qu'il n'a jamais vue. Il fournit au planning la durée médiane, une marge propre au patient (90e centile prévu moins médiane), la loi du nombre de nuits, dont l'espérance arrondie donne les nuits prévues, et l'entrée éventuelle la veille.

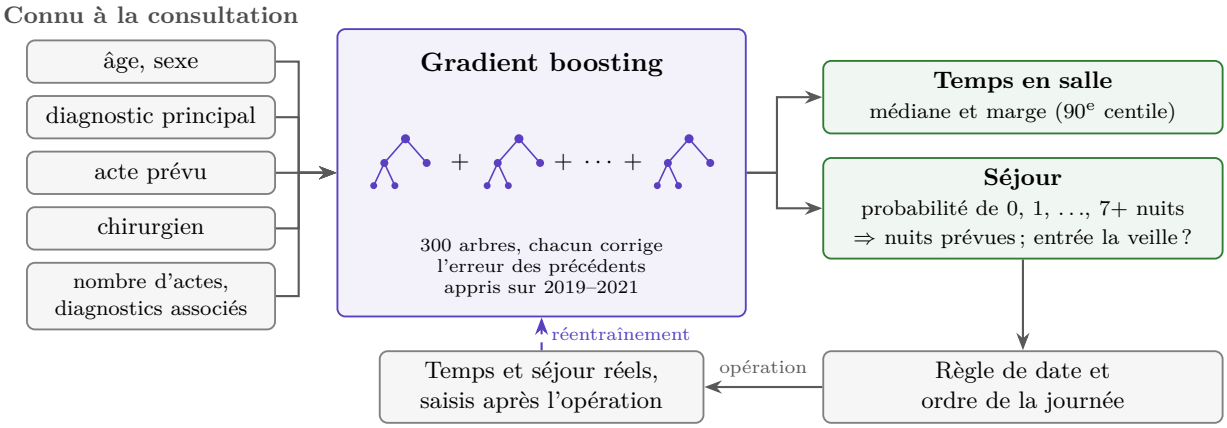


Figure 6 – Le modèle de prévision : ce qui entre, ce qui sort, et son réentraînement sur les durées réelles.

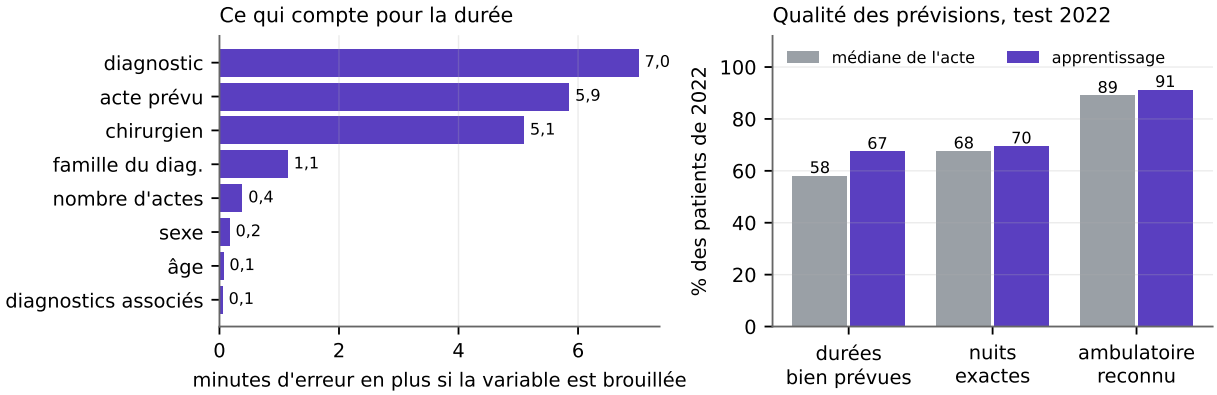


Figure 7 – Ce que donne le modèle sur les patients de 2022. À gauche, importance des variables : hausse de l'erreur moyenne quand on mélange au hasard les valeurs d'une variable. À droite, qualité des prévisions face à la médiane de l'acte.

Testé sur 2022, le modèle prévoit bien 67,5 % des durées, contre 58 % pour la médiane de l'acte, avec une erreur moyenne de 14,5 minutes au lieu de 18,1 et une marge plus serrée (26 minutes au lieu de 36) qui couvre toujours 90 % des cas (figure 7). Le diagnostic, l'acte prévu et le chirurgien pèsent le plus ; l'âge et le sexe ne comptent presque pas. Il fait mieux que la médiane pour chacun des 18 chirurgiens. Pour le séjour, le gain est plus modeste : il reconnaît l'ambulatoire dans 91 % des cas au lieu de 89 %, et trouve le nombre exact de nuits pour 70 % des patients au lieu de 68 %. Ces écarts modestes sont attendus : l'acte prévu explique déjà la moitié de la variabilité de la durée (coefficient de détermination de 0,51, contre 0,67 pour le modèle), et ce qui reste dépend surtout de ce que l'on ne sait pas à la consultation, comme les difficultés pendant l'opération ou les complications. Pour le séjour, l'acte dit presque à lui seul si le patient rentre le soir même. Les séjours raccourcissant d'année en année (de 2,95 nuits en 2019 à 2,38 en 2022 pour un patient hospitalisé), le modèle devra être réentraîné régulièrement. La section 7.3 mesure ce que ces prévisions changent au planning.

5.4 Les patients fantômes

Pourquoi des fantômes. La date d'un patient est donnée sans connaître les patients qui consulteront les jours suivants. Une règle qui ne regarde que les patients déjà datés voit les semaines lointaines presque vides et y envoie les nouveaux patients ; ces semaines se remplissent pourtant avec les consultations suivantes, et les pics réapparaissent plus tard. Les patients fantômes corrigent ce biais. Ce sont des patients *prévus*, pas encore réels : chaque matin, on estime la charge qui arrivera encore dans chaque vacation des neuf semaines à venir, et les lits qu'elle occupera. La règle de date juge alors chaque date sur la courbe des lits *attendue* :

$$E_n = \underbrace{R_n}_{\text{patients datés}} + \underbrace{G_n}_{\text{fantômes programmés}} + \underbrace{U_n}_{\text{fantômes d'urgence}}, \tag{11}$$

pour chaque nuit n (figure 8).

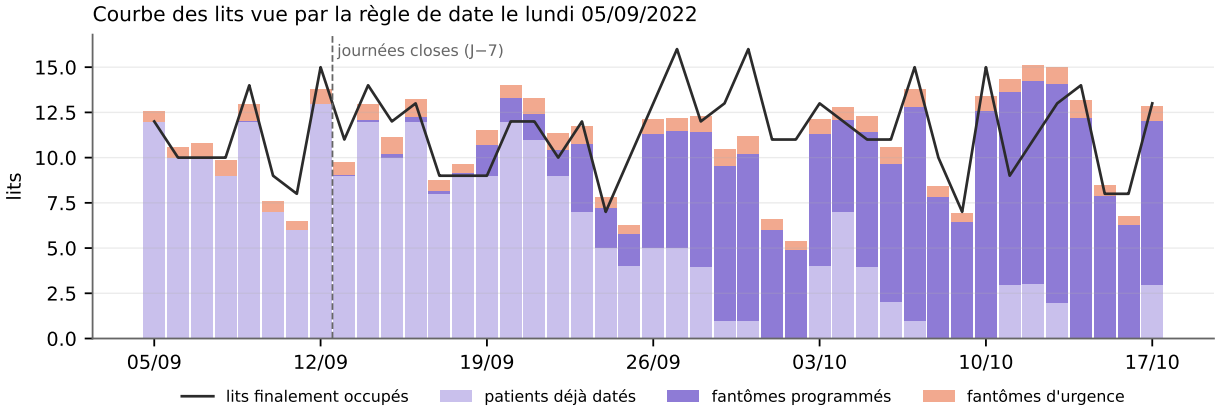


Figure 8 – Courbe des lits vue par la règle de date le lundi 5 septembre 2022, sur les six semaines suivantes (chaîne hybride). Les semaines proches sont déjà remplies par des patients datés, les lointaines surtout par des fantômes ; les creux sont les week-ends, que la cible veut plus bas. Le trait noir montre les lits finalement occupés.

La prévision des fantômes programmés. Pour une vacation v du chirurgien m, dans ℓ jours, déjà réservée à hauteur de rés_v minutes sur une capacité de cap_v minutes, la charge encore attendue vaut

$$g_v = \min\Big(\text{cap}_v - \text{rés}_v,\quad \alpha(\ell)\,\max\big(0,\ F_m\,\kappa_v\,\text{cap}_v - \text{rés}_v\big)\Big). \tag{12}$$

Trois quantités, apprises sur les données, la composent.

- F_m, le *remplissage habituel* du chirurgien : la part de capacité de ses vacations closes des huit dernières semaines, mélangée à sa valeur de janvier–avril quand ces vacations sont peu nombreuses, et plafonnée à 95 %. Elle suit un chirurgien dont l'activité augmente ou baisse.
- κ_v, l'*effet des vacances* : 1 en temps normal, 0,56 pendant les vacances, ponts et fériés, rapport des minutes programmées par jour ouvré mesuré sur 2019 et 2021.
- $\alpha(\ell)$, la *part de l'écart encore comblée* ℓ jours avant : 0,40 à deux semaines, 0,65 à trois, 0,82 à quatre et 0,97 à six. Plus la date est proche, moins il reste de consultations pour remplir la vacation. Elle est apprise en rejouant janvier–avril 2022.

La charge g_v est répartie entre trois classes de séjour (ambulatoire, une à deux nuits, trois nuits et plus) selon les habitudes du chirurgien, puis convertie en lits : chaque minute fantôme de la classe c occupe, o nuits après l'opération, $K_{m,c}(o)$ lit, profil appris sur ses patients passés. D'où $G_n = \sum_v \sum_c g_v\,\pi_{m,c}\,K_{m,c}(n - j_v)$.

Les fantômes d'urgence. Le nombre d'urgences est prévisible en moyenne : environ une par jour du lundi au vendredi, deux fois moins le mardi et presque aucune le week-end, avec 1,15 nuit par urgence (2019, 2021 et janvier–avril 2022). Les fantômes d'urgence U_n placent ces lits attendus sur les nuits à venir ; chaque jour écoulé, la prévision est remplacée par les urgences réellement arrivées.

La vie d'un fantôme. Les fantômes sont recalculés chaque matin, à partir de l'état réel des réservations. Un fantôme ne réserve rien : il pèse seulement dans l'évaluation des dates. Trois cas se présentent (figure 9).

- *Les patients remplacent les fantômes* (lundi 17 octobre). Sept semaines avant, 3 patients seulement sont datés, mais la règle compte 13,4 lits attendus. À chaque consultation, un patient daté prend la place d'un fantôme : 10 patients trois semaines avant, 13 la dernière semaine. La somme reste entre 11,6 et 13,8 lits, pour 13 lits finalement occupés : la nuit n'a jamais paru vide.
- *Moins de patients que prévu* (jeudi 20 octobre). La prévision attendait 14 lits ; personne ne remplace les fantômes, qui s'effacent d'eux-mêmes à mesure que la date approche, jusqu'à 8,9 lits la dernière semaine, pour 8 finalement occupés. Ils n'ont rien bloqué : ils ont seulement orienté quelques patients vers d'autres jours.
- *Plus de patients que prévu* (mardi 27 septembre). Un fantôme ne peut pas dépasser la place libre de sa vacation : les patients en plus comptent aussitôt, et la nuit attendue monte à 15,7 lits, pour 16

occupés.

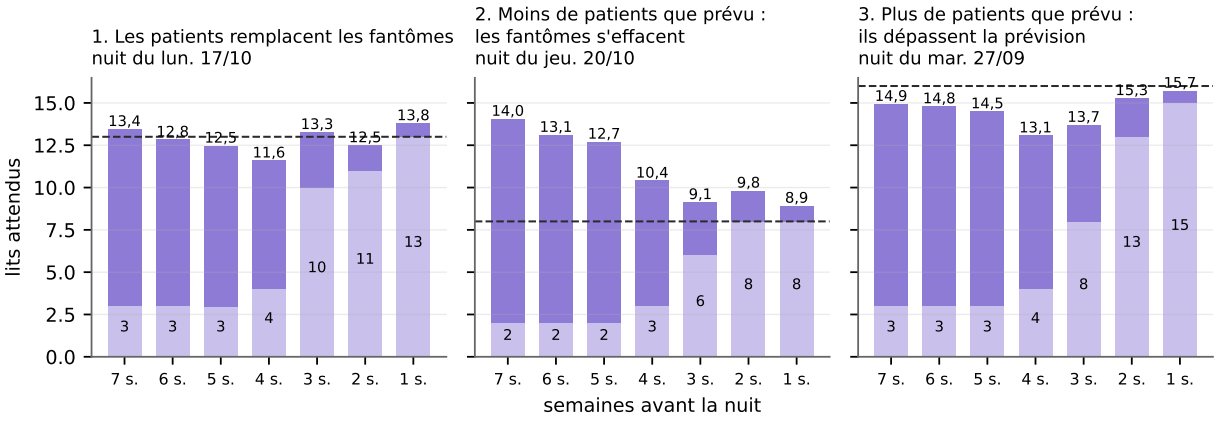


Figure 9 – Les trois cas, sur trois nuits de semaine de l'automne 2022. Chaque barre est la nuit vue par la règle de date une à sept semaines avant : en clair les patients déjà datés (nombre écrit), en foncé les fantômes ; le pointillé marque les lits finalement occupés.

Une prévision juste là où elle compte. Sans fantômes, la courbe vue à la consultation se trompe de 7 lits en moyenne quadratique six semaines avant ; avec eux, de 2,3 lits (figure 10). C'est à cet horizon, quand la plupart des dates sont données, que la règle a besoin d'une courbe juste.

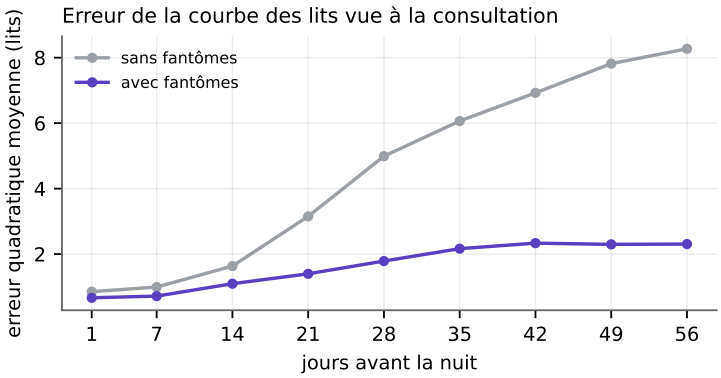


Figure 10 – Erreur de la courbe des lits vue à la consultation, selon le nombre de jours avant la nuit (chaîne hybride, mai–décembre 2022, urgences comprises).

À retenir

Le problème est découpé en trois niveaux, et ce qui manque à la consultation est prévu : la durée et le séjour par apprentissage, la demande à venir par des patients fantômes. Il reste à choisir, à chaque niveau, la méthode de résolution : c'est ce que les trois études du groupe ont exploré.

6 Résolution : des trois études à la chaîne hybride

Ce que cette partie établit. Chaque étude du groupe a résolu les niveaux 1 et 3 du modèle avec sa métaheuristique ; chacune a un point fort, qui a une cause dans ses choix de modèle, et un prix. La chaîne hybride garde chaque point fort et corrige son prix ; le système multi-agents et le moteur de reprogrammation la font vivre face aux aléas.

6.1 Trois études, trois points de vue

Trois études ont d'abord été menées en parallèle. Chacune a construit une chaîne complète : une grille de vacations et un ordre de passage pour la journée, obtenus par sa métaheuristique, et une règle simple pour

dater les patients, sans métaheuristique (section 5.2) ; chacune a fait ses propres choix de modèle (tableau 5).

Coût et itérations. Une métaheuristique ne connaît d'une solution que son *coût* : un nombre qui résume sa qualité et qu'elle cherche à rendre le plus petit possible. Chaque étude a défini le sien. À chaque *itération*, la méthode modifie une solution par un *mouvement* et calcule le coût obtenu ; le nombre d'itérations mesure son effort de calcul.

Tableau 5 – Les trois études d'origine : ce que chacune a choisi à chaque niveau.

	Recherche tabou	Algorithme génétique	Recuit simulé
Grille	reconstruite de zéro par demi-journées ; volume de chaque chirurgien figé à l'actuel	par demi-journées ; quotas tirés de la demande, salle 1 ouverte, 182 h offertes par semaine au lieu de 144	créneaux actuels conservés, on change qui les occupe ; volume à ±10 %
Coût de la grille	adéquation à la demande, variance relative des lits, irrégularité	lits des nuits de semaine (×4), admissions, temps perdu, délai, salles	écart des lits à une cible nuit par nuit, admissions, temps de travail
Date (règle)	premier jour possible, meilleure vacation de ce jour ; journée fermée à 85 %	12 dates notées par le coût, 2 proposées, le patient prend la plus proche	première date libre
Journée	recherche tabou	algorithme génétique	recuit

6.1.1 Recherche tabou

La recherche tabou fait évoluer une seule solution. À chaque itération, elle examine des voisins, passe au meilleur, même s'il est moins bon, et interdit pendant quelques itérations de défaire ce qu'elle vient de faire : c'est la *durée d'interdiction*, qui l'empêche de tourner en rond. Un mouvement interdit reste permis s'il donne la meilleure solution jamais vue. Dans l'étude d'origine, la grille est reconstruite de zéro : une construction gloutonne en partie aléatoire, puis une recherche tabou autorisée à dépasser un moment le volume d'heures moyennant une pénalité qui s'ajuste (*oscillation stratégique*), enfin un *path relinking* entre les meilleures solutions ; les meilleures grilles sont rejouées sur une année. Le coût additionne l'écart entre la demande et le temps offert à chaque chirurgien, la variance relative des lits prévus (poids 20) et l'irrégularité de la semaine (poids 0,3). Relancée telle quelle, l'étude ramène la variance des lits de 14,9 à 10,0 sur son propre jeu d'essai, et tout le gain vient du terme des lits : sans lui, elle reste à 14,7.

6.1.2 Algorithme génétique

L'algorithme génétique fait évoluer une *population* de solutions. À chaque génération, il choisit des parents par tournoi, les *croise* pour former des enfants, applique quelques mutations et garde les meilleures solutions. Pour la grille, le croisement prend chaque journée du cycle à l'un ou l'autre parent, puis répare les volumes des chirurgiens. L'étude a fait varier le poids de chaque terme du coût : multiplier par quatre le poids des lits donne le meilleur lissage à ressources presque égales (écart-type des lits des nuits de semaine de 1,41 contre 1,91 à poids égaux), et lisser fortement l'ambulatoire fait ouvrir davantage de salles.

6.1.3 Recuit simulé

Le recuit simulé tire *un* voisin au hasard. Il l'accepte toujours s'il est meilleur, et sinon avec la probabilité $e^{-\Delta/T}$, où Δ est la dégradation du coût et T une *température* qui baisse au fil des itérations : au début il explore largement, à la fin il n'accepte presque plus que des améliorations. L'étude d'origine a comparé quatre fonctions de coût : sans normalisation, le délai écrase les lits, et la seule fonction qui améliore tous les indicateurs à la fois mesure l'écart des lits à une *cible* nuit par nuit, plus basse le week-end. Sa grille garde les créneaux actuels et ne change que leur occupant, sur 16 des 33 créneaux.

6.1.4 Mouvements et recherche

Aux niveaux 1 et 3, les trois études ne modifient pas une solution de la même façon (tableau 6).

Tableau 6 – Les mouvements de chaque étude.

	Tabou	Génétique	Recuit
Grille	donner une demi-journée à un autre chirurgien ; fermer une demi-journée ; déplacer un chirurgien vers une demi-journée libre ; échanger deux chirurgiens	croisement par journées entières ; mutations : échanger deux demi-journées, regrouper le matin et l'après-midi d'un chirurgien, échanger deux journées	échanger les occupants de deux créneaux (8 fois sur 10) ou donner un créneau à un autre chirurgien
Journée	échanger deux patients ; déplacer un patient à une autre place de l'ordre	croisement qui garde l'ordre relatif d'un parent ; départs par ordres simples, comme les ambulatoires d'abord	déplacer ou échanger des patients

Pour voir comment chaque algorithme cherche, indépendamment des choix de son étude, nous les avons lancés sur le même problème : la grille de la section 5.2 et son coût (2), depuis cinq grilles aléatoires (figure 11). Le recuit descend le plus vite et finit le plus bas (3,02 après 40 000 itérations, contre 3,14 pour le tabou et 3,20 pour le génétique) ; le génétique, qui répartit son effort sur toute une population, converge le plus lentement et varie le plus d'un départ à l'autre.

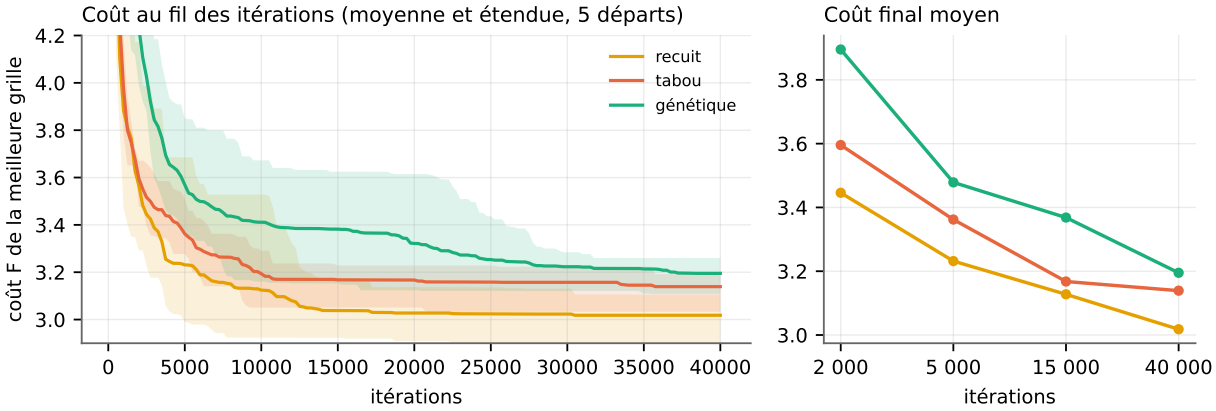


Figure 11 – Les trois algorithmes sur le même problème de grille. À gauche, coût de la meilleure grille au fil des itérations (moyenne et étendue de cinq départs) ; à droite, coût final selon le nombre d'itérations, une recherche par nombre d'itérations.

Leurs réglages ont été choisis en faisant varier un paramètre à la fois (figure 12). Le tabou est sensible au nombre de voisins examinés ; une durée d'interdiction plus courte (5 au lieu de 15) baisse un peu son coût, et le recuit est presque insensible à sa température. Mais surtout, une grille de coût plus faible ne lisse pas mieux les lits une fois rejouée sur des patients : sur les 72 grilles du réglage, coût et variance des lits ne sont pas liés ($r = -0{,}01$). Nous avons donc gardé les réglages d'origine (15 pour la durée d'interdiction), et c'est pourquoi l'étude tabou départageait ses grilles par simulation, ce que la chaîne hybride reprend.

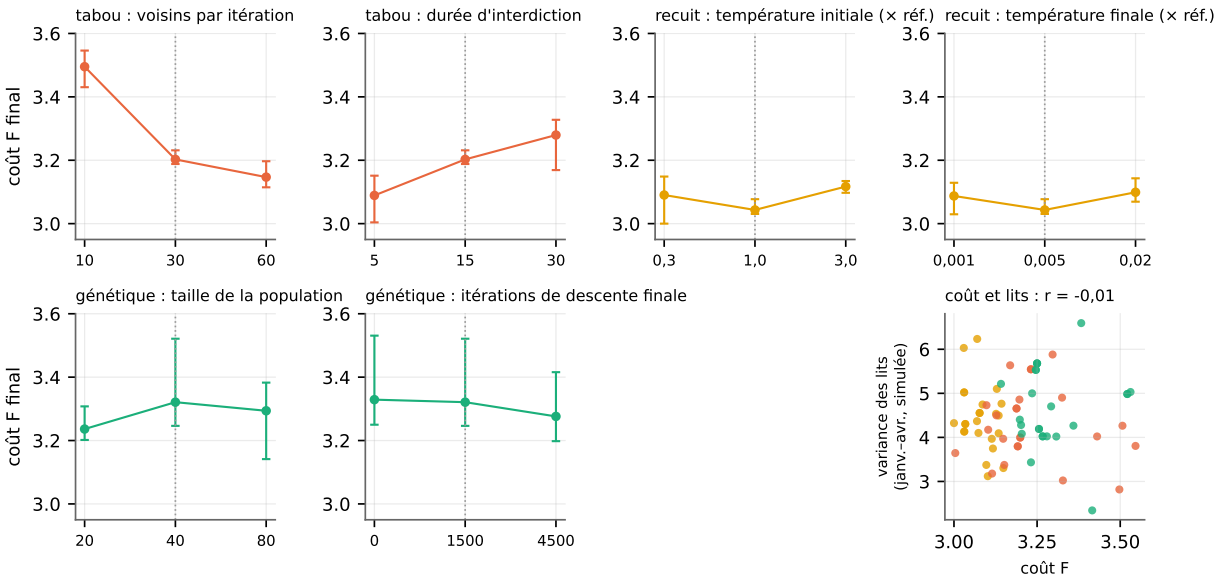


Figure 12 – Réglage des paramètres sur le problème de la grille : coût final selon la valeur d'un paramètre, les autres à leur valeur de base (pointillé), 15 000 itérations, moyenne et étendue de quatre départs. En bas à droite, coût et variance des lits de chaque grille rejouée sur février–avril.

6.1.5 Les points forts de chaque étude, sans et avec patients fantômes

Le tableau 7 rejoue la grille de chaque étude sur les patients de mai à décembre 2022 et ne retient que les critères que leurs coûts cherchent à améliorer. Pour comparer les grilles à règle égale, chacune est datée par la même règle, qui choisit dans une fenêtre de 14 jours la date qui lisse le mieux la courbe des lits attendus : d'abord avec les seuls patients déjà datés, puis en y ajoutant les patients fantômes de la section 5.4.

Tableau 7 – Les valeurs clés de chaque étude, sans et avec patients fantômes (mai–décembre 2022, dix ordres de consultation). Dans chaque colonne, la meilleure des trois études est en **gras sur fond vert** ; la grille actuelle sert de repère.

	Sans patients fantômes				Avec patients fantômes			
Grille	Variance des lits	É.-t. admissions	Délai médian (j)	Heures opérées	Variance des lits	É.-t. admissions	Délai médian (j)	Heures opérées
actuelle	5,7	3,93	23	51 %	4,9	3,86	23	51 %
tabou	**4,4**	3,37	30	48 %	**3,5**	3,28	31	48 %
génétique	6,5	3,56	**15**	43 %	6,4	3,45	**15**	43 %
recuit	5,5	**3,22**	24	**53 %**	5,0	**3,15**	24	**53 %**

Variance des lits : nuits de semaine hors vacances. Patients sans date avec fantômes : actuelle 15, tabou 20, génétique 2, recuit 6. Délai pour 90 % des patients : 115, 148, 27 et 88 jours.

Chaque étude a un point fort net, et il a une cause dans ses choix de modèle :

— la grille du **tabou** lisse le mieux les lits, parce que son coût vise presque uniquement les lits ; mais avec le volume de chaque chirurgien figé, les plus demandés manquent de temps : 20 patients sans date, un délai et une occupation du bloc les moins bons ;

— la grille du **génétique** donne les délais les plus courts (90 % des patients en 27 jours), mais en ouvrant la salle 1 et en offrant 182 heures par semaine au lieu de 144 : ses vacations restent peu remplies (43 % des heures opérées) et ses lits sont les moins réguliers ; sa règle de date, qui choisit parmi douze dates, lisse les lits de la grille actuelle (variance 5,6) mais repousse les patients, avec un délai médian de 95 jours et 37 patients sans date ;

— la grille du **recuit**, qui ne change que l'occupant de quelques créneaux, rend l'ambulatoire le plus régulier et occupe le mieux le bloc, mais lisse peu les lits.

Pour la journée, les trois méthodes atteignent le même coût, 988 contre 1 157 dans l'ordre d'inscription, et réduisent de 5 à 2 les sorties de l'ambulatoire après 20 h sur 34 journées. Sur les 274 vacations de 4 à 7 patients, où l'énumération de tous les ordres donne l'optimum, le génétique et le recuit l'atteignent partout avec 1 000 itérations, le tabou sur 273 ; le meilleur ordre simple seul l'atteint 233 fois. Le tabou est le plus rapide (119 ms par vacation contre 215 pour le génétique).

Les patients fantômes. Ajouter les fantômes baisse la variance des lits de 0,5 à 0,9 point sur la grille actuelle et sur celles du tabou et du recuit, et rend les admissions un peu plus régulières sur toutes les grilles ; le délai et l'occupation du bloc ne bougent pas. Sur la grille du génétique, qui offre plus d'heures que la demande, la variance ne change presque pas : il y a presque toujours de la place tôt, et les fantômes n'ont rien à corriger. Ils ne dégradent donc aucun critère, et leur gain est le plus fort sur les grilles serrées : la chaîne hybride les garde, et toute la suite du rapport les utilise.

6.2 Approche hybride

Le cheminement. La chaîne hybride est née de la comparaison des trois études, en trois temps.

1. *Isoler le point fort de chaque étude*, critère par critère (tableau 7) : le tabou lisse le mieux les lits, le génétique donne les délais les plus courts, le recuit rend l'ambulatoire le plus régulier et occupe le mieux le bloc. Pour chacun, la cause est dans les choix de l'étude : un coût qui vise les lits pour le tabou, des quotas qui suivent la demande pour le génétique, une cible nuit par nuit et un volume borné pour le recuit.
2. *Comprendre ce que coûte chaque point fort* : le tabou fige le volume des chirurgiens et allonge les délais ; le génétique ajoute des heures de bloc, et sa règle de date repousse les patients ; le recuit change trop peu la grille pour lisser les lits.
3. *Prendre le meilleur de chaque étude et corriger son prix* (tableau 8), puis ajouter les patients fantômes, qui ne dégradent aucun critère et lissent davantage les lits.

Tableau 8 – Ce que la chaîne hybride reprend de chaque étude, et ce qu'elle corrige.

Étude	Repris	Corrigé
Tabou	viser les lits dès la grille ; juger les grilles en les rejouant sur des patients ; la recherche tabou pour la journée, la plus rapide	volume figé ⇒ volume libre entre 75 et 150 % de l'actuel, pour suivre la demande
Génétique	quotas qui suivent la demande ; croisement par journées entières ; regarder les lits pour choisir la date ; les ordres simples comme départ de la journée	heures en plus ⇒ heures de bloc constantes ; douze dates ⇒ fenêtre de 14 jours après la première date possible
Recuit	la cible nuit par nuit, plus basse le week-end ; le recuit, qui cherche le mieux une grille (figure 11) ; un volume borné	cible étendue aux vacances ; plafond de lits en vacances
Nouveau	les patients fantômes dans la règle de date	—

La chaîne hybride (figure 13) assemble ces briques à chaque niveau.

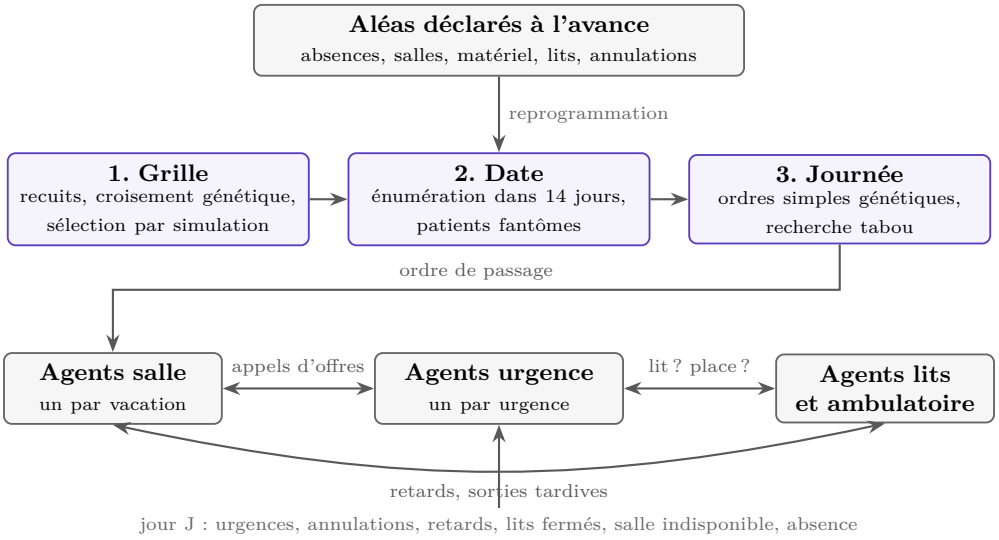


Figure 13 – La chaîne complète : trois niveaux de planification, le système multi-agents du jour J et la reprogrammation des aléas déclarés à l'avance.

Niveau 1. Huit recuits de 15 000 itérations, avec un poids des lits de 1 ou de 4 et quatre départs, produisent des grilles candidates ; les meilleures sont croisées par journées entières, comme dans l'algorithme génétique, puis affinées par un recuit plus court (figure 14). Le coût (2) n'est qu'une approximation des lits : il ne voit ni l'ordre d'arrivée des patients ni la règle de date. Les seize candidates sont donc rejouées sur janvier–avril 2022 avec la règle de date et ses fantômes, et l'on retient celle qui donne la plus faible variance des lits les nuits de semaine de février à avril sans laisser plus de patients sans date que la meilleure, à deux près. Ce choix par simulation compte : la grille retenue n'est pas celle de plus faible coût, et deux candidates de faible variance sont écartées parce qu'elles laissent 16 et 19 patients sans date.

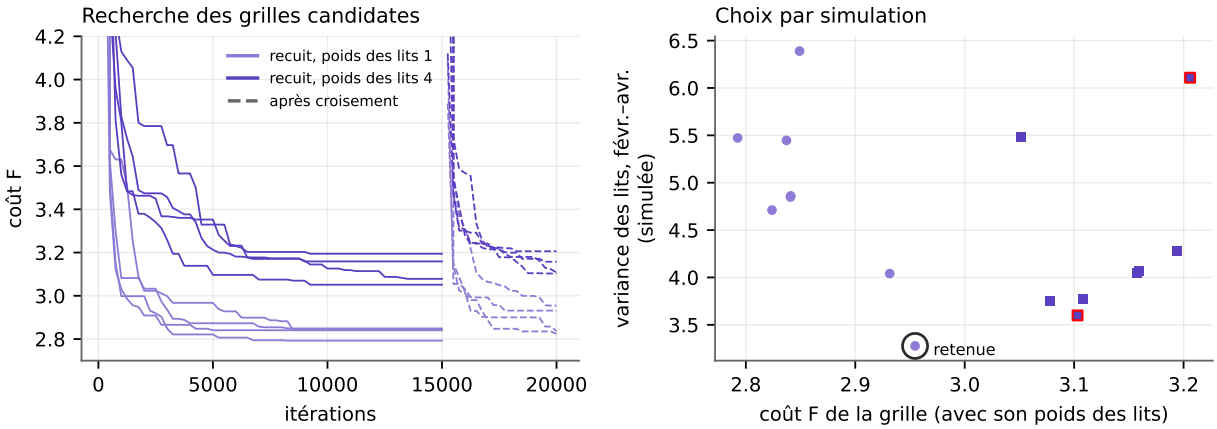


Figure 14 – Construction de la grille hybride. À gauche, évolution du coût des seize recherches ; à droite, coût de chaque candidate, avec son propre poids des lits, et variance des lits obtenue en la rejouant sur février–avril (contour rouge : plus de deux patients sans date, candidate écartée).

Niveau 2. La règle de date énumère les vacations de la fenêtre de 14 jours et les juge sur la courbe attendue (11), patients fantômes compris (algorithme 1). Avec au plus 28 vacations candidates, l'énumération donne la meilleure date exacte en une fraction de milliseconde (section 5.2).

Algorithme 1 . Règle de date à la consultation (jour t, patient p).

$V \leftarrow$ vacations réalisables de $m(p)$, capacité réduite des vacances comprise;
if $V = \varnothing$ **then return** sans date;
$j_1 \leftarrow \min_{v \in V} j_v$;
for $v \in V$ *avec* $j_v \leq j_1 + 14$ **do**
    $x \leftarrow$ minutes fantômes de v remplacées par p (sa classe de séjour d'abord);
    $\Phi_p(v) \leftarrow$ hausse de $\mathcal{E}_f(E)$ sur W_t si p entre dans v et remplace x;
proposer les deux jours de plus petit Φ_p ; le patient choisit $v^\star$;
affecter p à $v^\star$; mettre à jour R et retirer x des fantômes de $v^\star$;

Niveau 3. La journée part du meilleur des ordres simples de l'algorithme génétique, puis une recherche tabou l'améliore : 20 voisins tirés par itération, par insertion ou échange ; un patient déplacé interdit pendant 7 itérations, 1 000 itérations au total. Les places ambulatoires sont attribuées par coloriage d'intervalles, ce qui est optimal.

6.3 Face aux aléas

Le plan est construit avec des durées estimées et une demande prévue. Deux sortes d'aléas le bousculent. Les *aléas connus à l'avance*, quelques jours ou semaines avant, laissent le temps de reprogrammer à froid : congés ou formation d'un chirurgien, maintenance d'une salle, fermeture de lits, annulation. Les *aléas du jour* demandent une réaction en quelques minutes.

Le jour de l'opération : le système multi-agents

Chaque ressource est représentée par un agent qui ne connaît que ce qu'il voit, et les agents se coordonnent par messages, sans décideur central.

— *Agent salle*, un par vacation : il connaît sa file de patients et l'heure d'entrée de l'acte en cours, mais pas sa durée réelle ; il constate seulement qu'un acte n'est pas fini à l'heure prévue.

— *Agent urgence*, un par urgence : il cherche une salle pour son patient.

— *Agent lits* et *agent ambulatoire* : ils acceptent ou refusent une hospitalisation ou une admission, et l'agent ambulatoire fait avancer un patient qui sortirait après la fermeture de l'unité, à 20 h.

Les agents négocient par appel d'offres : l'agent qui a un besoin interroge les autres, chacun répond par une proposition ou un refus, et l'initiateur retient la meilleure. Le tableau 9 donne la réponse à chaque aléa, et ce que ferait la même journée sans agents.

Tableau 9 – Les aléas du jour et la réponse, sans et avec agents.

Aléa	Sans agents	Avec agents
Urgence U1 (24 h) ou U2 (72 h)	créneau d'urgence, sinon vacation d'un chirurgien qui opère des urgences et a de la place *au planning*, le jour même ou dans le délai, en fin de programme	appel d'offres à toutes les salles qui peuvent l'accueillir, y compris celles qui ont fini leur programme ou perdu leur chirurgien ; sans offre, l'urgence attend un créneau libéré ; les U1 sont servies d'abord
Retard : un acte dure plus que prévu	subi	l'ambulatoire fait avancer les patients qui sortiraient après 20 h ; dépassement accepté jusqu'à 60 minutes ; au-delà, le dernier patient non commencé est reporté au plus tôt
Annulation du jour	place perdue	la salle annonce un créneau libre aux urgences en attente
Salle en panne quelques heures	panne subie, programme décalé	la vacation passe dans une salle libre ; sinon elle reprend après la panne, même règle des 60 minutes
Chirurgien absent sans prévenir	ses patients sont reportés au plus tôt dans ses vacations suivantes	idem ; sa salle libérée accueille les urgences
Lits fermés	subi	l'agent lits refuse une hospitalisation sans lit libre et prévient l'ambulatoire

Une urgence n'a pas de chirurgien attitré : elle est opérée par le chirurgien de la salle qui l'accueille, parmi les neuf qui opèrent des urgences dans l'historique. *Reporter au plus tôt* un patient signifie le placer dans la première vacation de son chirurgien, à partir du lendemain, où il tient avec un débordement d'une heure au plus.

Comment une urgence choisit sa salle. Prenons une fracture du poignet arrivée à 10 h, 40 minutes d'opération, ambulatoire. Trois salles répondent. La salle A finirait à 17 h 50 pour une vacation qui se termine à 17 h 30 : elle est éliminée, car une offre ne doit pas faire déborder la salle. La salle B l'opérerait à 16 h 40 : après 3 heures de surveillance, la patiente sortirait de l'ambulatoire à 20 h 20, après sa fermeture. La salle C peut l'opérer à 11 h 20 : c'est elle qui l'emporte. Lorsque plusieurs offres restent possibles, l'urgence prend celle qui entre le plus tôt et crée le moins de dépassement, après accord de l'agent lits ou ambulatoire.

Les aléas connus à l'avance : le moteur de reprogrammation

Absences, pannes ou annulations connues quelques jours ou semaines avant touchent des dates déjà données. Le moteur les traite en trois temps : la déclaration, la réponse sur les vacations touchées, puis la nouvelle date des patients déplacés.

Un formulaire unique. Une déclaration contient la catégorie, le motif en texte libre, la ressource touchée, le premier jour, la durée estimée, que l'on peut prolonger ou lever plus tôt, et si besoin une plage horaire. Les catégories sont : chirurgien absent, chirurgien indisponible quelques heures, salle indisponible, matériel manquant, lits fermés, annulation, patient non apte, patient non venu, et *autre*. Chaque catégorie connue se traduit en un ou plusieurs *impacts*, et le moteur a une réponse par impact (tableau 11). Une déclaration du jour même va au système multi-agents ; les autres vont au moteur de reprogrammation.

La catégorie « autre ». Pour un aléa qui n'entre dans aucune catégorie, le déclarant coche au moins un impact (tableau 10). Par exemple, une coupure d'eau chaude au bloc le matin se déclare comme la salle 2 indisponible de 7 h à 11 h, des actes de la salle 3 plus longs de 25 % et 4 admissions ambulatoires en moins ; le moteur applique la réponse de chacun de ces impacts.

Tableau 10 – La catégorie « autre » : les impacts que le déclarant peut cocher.

Impact	Précision demandée
Une salle ne peut pas être utilisée	salle, plage horaire
Un chirurgien ne peut pas opérer	chirurgien, plage horaire
Certains actes ne peuvent pas être faits	types d'actes
Des lits d'hospitalisation sont fermés	nombre
Moins d'admissions ambulatoires possibles	nombre par jour
Les actes vont durer plus longtemps	salle ou chirurgien, pourcentage
Information seulement, rien à déplacer	—

Quand une vacation est touchée : reloger, décaler, raccourcir ou fermer. Le moteur essaie dans cet ordre, et s'arrête à la première solution possible :

1. *Relogée* : même chirurgien, même jour, mêmes heures, dans une autre salle libre sur toute la plage. Aucun patient ne bouge. Cette réponse ne vaut que si c'est la salle qui manque.
2. *Décalée* : même salle, même durée, plage déplacée dans la journée hors de l'indisponibilité, si la salle et le chirurgien sont libres. Les patients gardent leur date, leurs heures changent.
3. *Raccourcie* : plage réduite à la plus longue partie restante, si elle dure au moins une heure. On garde les patients qui y tiennent encore, marges et réserve comprises ; les autres sont reprogrammés.
4. *Fermée* : s'il reste moins d'une heure, tous les patients sont reprogrammés.

La nouvelle date des patients déplacés. Un patient reprogrammé garde son chirurgien et reçoit une date au moins deux jours plus tard, dans les vacations existantes de la grille, choisie avec le même critère qu'en consultation (3). Aucune demi-journée n'est ajoutée au chirurgien pour rattraper une absence déclarée à l'avance. S'il n'y a pas de date avant son délai maximal, le patient est signalé « à arbitrer ». Un patient non apte est reprogrammé en priorité. Une place libérée au moins deux jours à l'avance est proposée aux patients du même chirurgien programmés plus tard : c'est le *comblement*.

Tableau 11 – Aléas connus à l'avance et réponse du moteur.

Aléa	Réponse
Chirurgien absent	ses vacations sont fermées ; ses patients sont reprogrammés dans ses vacations suivantes
Chirurgien indisponible quelques heures	vacation décalée dans la journée, sinon raccourcie, sinon fermée
Salle indisponible	vacation relogée, sinon décalée, sinon raccourcie, sinon fermée
Matériel manquant	seules les interventions qui en ont besoin sont reprogrammées
Lits fermés	les derniers hospitalisés programmés ces nuits-là sont reprogrammés
Annulation, patient non venu	place proposée à un autre patient du chirurgien (comblement)
Patient non apte	reprogrammé en priorité ; sa place est proposée à un autre patient
Autre	la réponse de chaque impact coché (tableau 10)

À retenir

La chaîne hybride assemble, niveau par niveau, la meilleure brique de chaque étude, et y ajoute les fantômes ; les agents et le moteur de reprogrammation la font vivre face aux aléas. Il reste à vérifier que chaque brique tient sa promesse sur des patients réels : c'est l'objet de la partie suivante.

7 Expérimentations et résultats

Ce que cette partie établit. D'abord que la chaîne hybride fait mieux que chacune des trois études (section 7.2) ; puis, brique par brique, d'où vient le gain et ce que coûte l'incertitude (section 7.3) ; enfin qu'il résiste aux aléas du jour, aux réglages, à la surcharge et aux aléas connus à l'avance.

7.1 Protocole et indicateurs

Toutes les méthodes sont jugées sur les patients de 2022, avec le même simulateur. Les durées et le modèle d'apprentissage sont appris sur 2019–2021, les grilles et les patients fantômes calés sur janvier–avril 2022, et les résultats mesurés sur mai–décembre 2022 : 2 055 patients programmés, 178 urgences et 245 nuits. Le simulateur avance jour par jour : les patients vus en consultation reçoivent leur date dans un ordre tiré au hasard, la journée à sept jours est close et celle du lendemain ordonnée. Les lits sont toujours comptés avec les *séjours réels*, urgences comprises, même lorsque le planning a utilisé un séjour prévu. Sauf mention contraire, chaque résultat est la moyenne de trois ordres de consultation, et la *référence* est la pratique simulée : grille actuelle, chaque patient à la première date libre de son chirurgien.

Le critère principal est la *variance des lits les nuits de semaine hors vacances* (section 4.2). Il est complété par le *pic de lits*, le *rapport week-end / semaine* (cible 0,70), l'*écart-type des admissions ambulatoires*, la part des *heures offertes opérées*, le *délai médian* et le *délai pour 90 % des patients* entre consultation et opération, les *patients sans date* dans les six mois et, le jour de l'opération, la part des urgences opérées à temps, le *dépassement du bloc* et les *patients reportés*.

7.2 La chaîne hybride face aux trois études

Les chaînes complètes des trois études (grille, règle de date et journée de chacune) sont comparées à la référence et à la chaîne hybride (figure 15). Le séjour est ici supposé connu, pour juger les méthodes et non les prévisions.

	variance lits (HV)	pic lits	week-end / semaine	é.-t. admissions	heures opérées %	sans date	délai médian	délai 90 %	ambu après 20 h	dépass. (min / j)
hôpital réel	20,1	24,0	—	3,85	—	—	—	—	—	—
référence	11,4	20,7	0,52	3,86	51	15	18	115	9,0	4,0
tabou	7,9	18,3	0,66	3,44	49	17	30	149	3,3	3,8
génétique	4,5	17,3	0,47	**2,76**	37	5	81	100	3,0	**2,7**
recuit	10,7	21,0	0,57	3,26	53	6	**20**	88	**1,0**	2,7
chaîne hybride	**3,4**	**17,0**	**0,69**	2,92	**55**	**0**	22	**51**	2,3	4,2

Figure 15 – Les chaînes complètes, mai–décembre 2022, sans aléa du jour (trois ordres de consultation). Dans chaque colonne, la meilleure des quatre chaînes est en vert foncé et en gras, la moins bonne en rouge ; pour le week-end, la meilleure est la plus proche de la cible 0,70. Les délais réels ne sont pas connus : la date de consultation n'est pas dans la base.

La chaîne hybride est la meilleure sur six des dix critères : la variance des lits (3,4, soit 3,4 fois moins que la référence et 6 fois moins que l'hôpital réel), le pic (17 lits contre 21), le respect de la cible du week-end (0,69 pour 0,70), les patients sans date (aucun), le délai pour 90 % des patients (51 jours contre 115) et l'occupation du bloc (55 % des heures offertes). Chaque étude, elle, paie son point fort : le génétique lisse bien les lits (4,5) et régularise le mieux l'ambulatoire, mais avec un délai médian de 81 jours, 37 % des heures opérées et un week-end vidé à 0,47 ; le tabou lisse moins une fois les patients datés (7,9) et allonge les délais extrêmes à 149 jours ; le recuit dépasse le moins le bloc mais lisse peu. La chaîne hybride dépasse un peu plus le bloc (4,2 minutes par jour) : elle remplit davantage ses vacations. Sur dix ordres de consultation, elle bat la référence à chaque fois sur tous les indicateurs de lits et d'ambulatoire (test de Wilcoxon apparié, $p = 0{,}002$). Du lundi au vendredi, les nuits restent proches les unes des autres (figure 16).

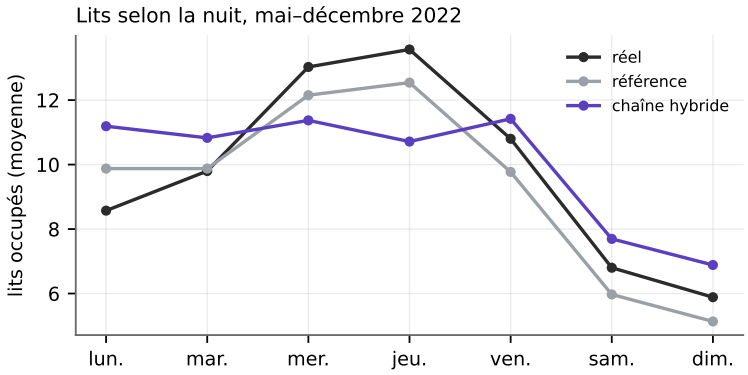


Figure 16 – Lits occupés selon la nuit de la semaine, mai–décembre 2022, urgences comprises.

7.3 Pas à pas : ce qu'apporte chaque brique

La chaîne hybride étant la meilleure, la suite ne travaille que sur elle, toujours avec ses patients fantômes, retenus à la section 6.1.5. Nous partons de la référence et ajoutons les briques une à une, dans l'ordre où le lecteur les a rencontrées (figure 17) : la grille, puis la règle de date ; puis nous levons l'hypothèse du séjour connu ; enfin nous ajoutons les aléas du jour, sans puis avec agents.

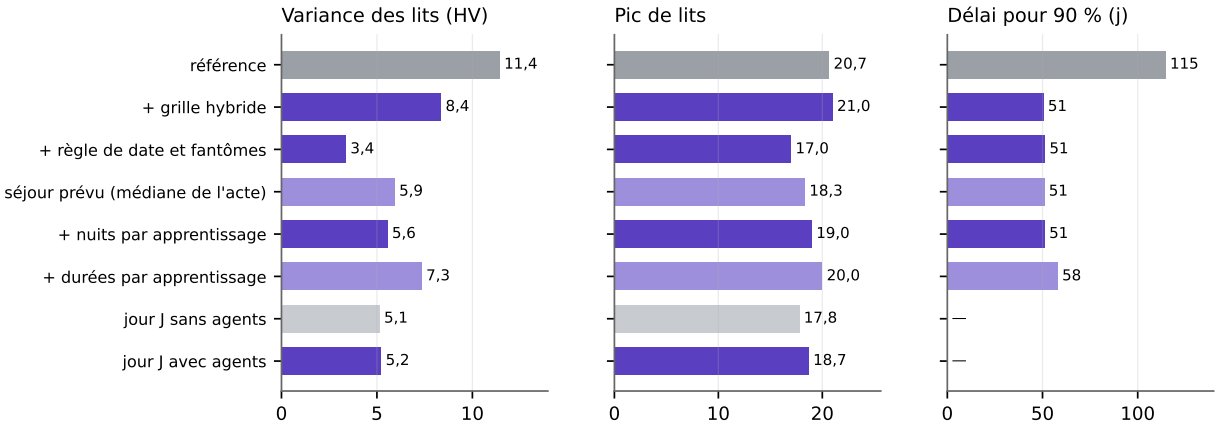


Figure 17 – Ce qu'apporte chaque brique, ajoutée l'une après l'autre (lits comptés avec les séjours réels). En violet foncé, les briques retenues ; en clair, les variantes écartées ; en gris, la journée sans agents. Jour J : dix tirages d'aléas, mêmes aléas avec et sans agents, nuits prévues par apprentissage.

La grille. La grille hybride, seule, fait passer la variance de 11,4 à 8,4 et le délai pour 90 % de 115 à 51 jours, sans patient sans date : elle donne à chaque chirurgien des vacations à la mesure de sa demande. Elle ne baisse pas encore le pic : c'est le rôle de la date.

La règle de date et ses fantômes. En datant chaque patient dans une fenêtre de 14 jours, sur la courbe des lits attendus fantômes compris, la variance tombe à 3,4 et le pic à 17 lits, pour trois jours de délai médian en plus. Sans fantômes, la même règle s'arrête à 4,2. La largeur de la fenêtre règle le compromis entre lissage et délai (figure 18) : sans fenêtre, la règle revient à la première date libre ; 7 jours ne gagnent qu'à moitié ; 14 jours prennent l'essentiel du gain ; 28 jours lisseraient encore (2,5), pour six jours de délai médian en plus. Nous retenons 14 jours.

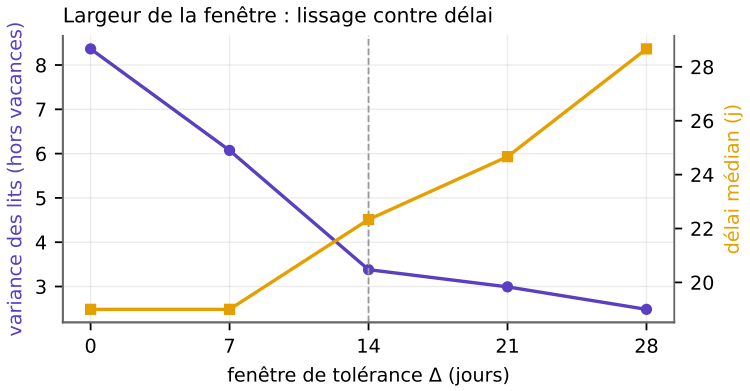


Figure 18 – La largeur de la fenêtre de tolérance, grille hybride et patients fantômes (trois ordres de consultation). Le pointillé marque la valeur retenue.

Des séjours prévus, et non connus. En pratique, le nombre de nuits n'est connu qu'à la sortie. Planifier avec la médiane de l'acte fait remonter la variance de 3,4 à 5,9 : c'est le prix de l'incertitude, qui apparaît dès que l'on quitte le cas idéal. Prévoir les nuits par apprentissage (section 5.3) en récupère une petite partie, 5,6, conformément au faible gain du modèle sur le séjour (70 % de nuits exactes contre 68 %). Prévoir aussi les durées par apprentissage a un effet inattendu : les marges du modèle sont plus serrées (26 minutes en moyenne contre 36), les vacations se remplissent davantage et le délai médian baisse de 22 à 18 jours, mais les lits redeviennent irréguliers (7,3) et le pic monte à 20 lits. Nous retenons donc les *nuits* prévues par apprentissage et la durée médiane de l'acte.

Le jour de l'opération. Le plan retenu est rejoué avec les durées réelles et les 178 urgences de 2022 : les 164 urgences des jours ouvrés arrivent à une heure tirée entre 7 h 30 et 17 h, les 14 du week-end et des fériés sont opérées par l'astreinte à leur date réelle. S'y ajoutent 4 % d'annulations du jour, 1 % de chirurgiens absents sans prévenir, une salle indisponible 2 à 4 heures un jour ouvré sur dix, et 2 à 4 lits fermés un jour sur vingt. La même journée est jouée sans agents (plan suivi tel quel, urgences placées par la règle de capacité) puis avec agents (tableau 12).

Tableau 12 – Le jour de l'opération, mai–décembre 2022 : chaîne hybride, fantômes et nuits prévues par apprentissage (dix tirages, mêmes aléas dans les deux colonnes).

	Sans agents	Avec agents
Urgences opérées dans leur délai (U1 : 24 h, U2 : 72 h)	86,6 %	**99,5 %**
Urgences opérées le jour même	55 %	**84 %**
U1 opérées le jour même (sur 14)	9,0	**11,7**
Attente d'une urgence opérée le jour même	116 min	**32 min**
Urgences placées dans un créneau libéré	—	53
Dépassement du bloc, par jour	10,5 min	**8,5 min**
Ambulatoires gardés la nuit (sortie après 20 h)	20	**12**
Patients programmés reportés (sur 2 055)	**20**	31
Variance des lits, semaine hors vacances	5,1	5,2

Les lits ne bougent presque pas (5,1 contre 5,2) : les annulations retirent quelques lits dans les deux cas, ce qui explique aussi que la variance soit un peu plus basse qu'en planification. Ce sont les urgences qui changent : avec agents, 99,5 % sont opérées dans leur délai contre 87 %, 84 % le jour même contre 55 %, et l'attente d'une urgence opérée le jour même est divisée par 3,6. L'essentiel vient des créneaux libérés : une salle qui finit en avance, perd un patient ou son chirurgien se propose aux urgences, ce que la règle sans agents, qui raisonne sur la capacité prévue, ne voit pas. Le dépassement du bloc baisse de 20 % et les ambulatoires gardés la nuit de 40 %. En contrepartie, les agents reportent davantage : quand un retard dépasse 60 minutes, le dernier patient non commencé est reporté, en moyenne 8 jours plus tard, plutôt que d'allonger la journée.

7.4 Toutes les combinaisons

L'escalier suit un chemin ; d'autres choix auraient pu changer les conclusions. La figure 19 croise donc trois façons de prévoir le séjour et trois façons de vivre le jour J.

	variance lits (HV)	pic lits	délai 90 %	urgences à temps %	urgences jour J %	dépass. (min / j)	patients reportés
médiane de l'acte · sans aléa	5,9	18,3	**51**	—	—	—	—
médiane de l'acte · aléas, sans agents	5,7	18,6	**51**	87,7	62	10,7	20
médiane de l'acte · aléas, avec agents	6,3	18,9	**51**	98,7	82	7,9	32
nuits par appr. · sans aléa	5,6	19,0	51	—	—	—	—
nuits par appr. · aléas, sans agents	**5,1**	**17,8**	51	86,6	55	10,5	20
► nuits par appr. · aléas, avec agents	5,2	18,7	51	**99,5**	**84**	8,5	31
durées et nuits par appr. · sans aléa	7,3	20,0	58	—	—	—	—
durées et nuits par appr. · aléas, sans agents	8,1	19,3	58	93,8	66	8,6	**19**
durées et nuits par appr. · aléas, avec agents	8,5	18,8	58	99,4	83	**6,2**	26

Figure 19 – Les neuf combinaisons sur la chaîne hybride. Dans chaque colonne, la meilleure valeur est en vert foncé, la deuxième en vert clair, la moins bonne en rouge ; la flèche marque la combinaison retenue. Planification : trois ordres de consultation ; jour J : dix tirages.

Deux conclusions tiennent dans tous les cas :

— *les agents aident toujours les urgences* : 99 % opérées dans le délai contre 87 à 94 %, plus de 80 % le jour même, et un dépassement du bloc plus faible, pour 0,1 à 0,6 point de variance et une dizaine de reports de plus ;

— *les durées par apprentissage arbitrent* entre délais et lits : délai médian plus court et dépassement le plus faible, mais la variance et le délai pour 90 % les plus hauts.

La combinaison retenue, nuits prévues par apprentissage et agents, est la meilleure sur les lits parmi celles qui servent 99 % des urgences à temps.

7.5 Sensibilité : réglages, vacances, surcharge

Les réglages précédents sont des choix ; cette section mesure jusqu'où les conclusions en dépendent.

La cible. Six couples de cibles ont été testés, chacun avec sa propre grille (figure 20). La cible fait ce qu'on lui demande : sans elle, le week-end remonte à 0,81 du niveau de semaine, contre la volonté du service, et plus elle est basse, plus il se vide, jusqu'à 0,65. La variance des nuits de semaine, elle, reste entre 2,4 et 3,5 quel que soit le couple : les écarts entre couples sont de l'ordre de la différence entre deux grilles construites avec des tirages différents. Le couple 0,70 / 0,65 n'est donc pas un optimum mesuré, mais une *prise de position* fondée sur le personnel disponible le week-end et en vacances, qu'un autre établissement peut régler autrement sans perdre la régularité de la semaine. En vacances, l'occupation reste vers 0,75 du niveau de semaine : la demande et le plafond limitent l'effet de la cible.

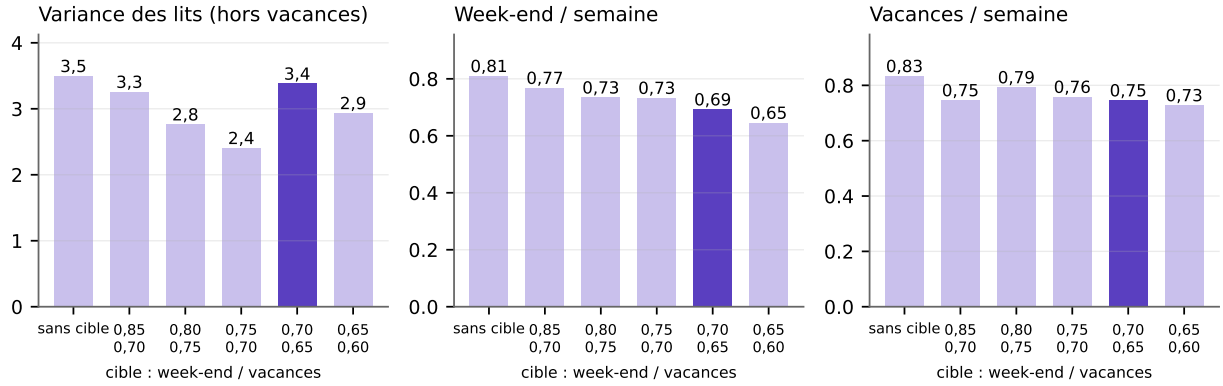


Figure 20 – Choix de la cible : chaque couple a sa grille et sa règle de date. En foncé, le couple retenu.

Les vacances et la grille régulière. La grille sur deux semaines lisse un peu mieux qu'une grille libre sur quatre semaines, au prix d'un délai pour 90 % plus long, et elle est plus simple pour les équipes (tableau 13). Le plafond de 12 lits en vacances change peu les résultats : la cible pousse déjà les vacances vers 0,75 ; il sert de garantie de capacité plus que de levier de lissage.

Tableau 13 – Grille régulière et plafond des vacances (règle hybride).

Grille	Plafond	Variance	Week-end / sem.	Vacances / sem.	Délai médian / 90 % (j)
libre sur 4 semaines	non	3,6	0,69	0,73	23 / 44
libre sur 4 semaines	oui	3,5	0,70	0,72	23 / 45
paire / impaire	non	3,2	0,68	0,76	22 / 51
paire / impaire	oui	3,4	0,69	0,75	22 / 51

La réserve pour les urgences. Faire varier la réserve de 0 à 15 % du temps de chaque vacation (avec 0 à 4 lits et admissions) montre qu'elle compte surtout *sans agents* (tableau 14) : à 15 %, la part des urgences à temps passe de 87 à 94 %, mais le délai médian des programmés double. Avec agents, les urgences sont servies à 99 % à tous les niveaux, parce que les créneaux libérés suffisent ; une réserve plus grande réduit seulement le dépassement. La réserve de 5 % lisse le mieux les lits en gardant des délais courts.

Tableau 14 – Réserve pour les urgences : planification (graine 0) et jour J (dix tirages), nuits prévues par apprentissage. Urgences et dépassement : sans agents / avec agents.

Réserve (temps, lits, admissions)	Délai médian / 90 %	Variance	Urgences à temps	Dépassement (min/j)
0 %, 0, 0	19 / 45	7,4	86 % / 99,5 %	13,0 / 8,6
5 %, 2, 2	22 / 51	**5,0**	87 % / 99,5 %	10,5 / 8,5
10 %, 3, 3	31 / 65	5,3	86 % / 99,1 %	8,2 / 6,0
15 %, 4, 4	44 / 81	6,2	94 % / 99,5 %	8,7 / 6,1

La surcharge. Avec 10 à 30 % de patients en plus, à heures de bloc constantes (figure 21), la référence sature vite : à +30 %, elle laisse 173 patients sans date, contre 16 pour la chaîne hybride, dont la grille suit la demande de chaque chirurgien. Les lits restent plus réguliers, 5,1 contre 10,4 ; en contrepartie, le délai médian monte plus vite (79 jours contre 59), puisque la chaîne date des patients que la référence renonce à dater.

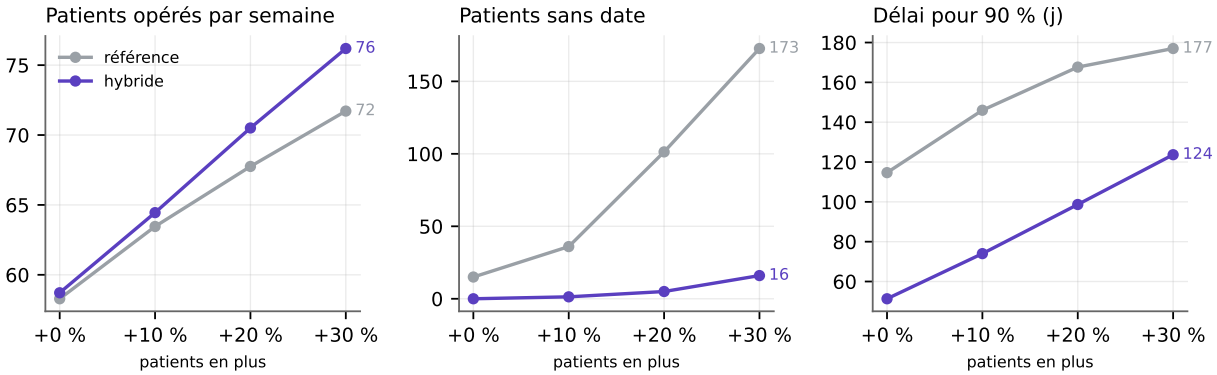


Figure 21 – Surcharge de patients programmés, à heures de bloc constantes (copies de patients réels).

7.6 Les aléas connus à l'avance

Les semaines de 2022 où un chirurgien avait des vacations dans la grille actuelle sans opérer servent de calendrier de congés ; avec elles, le modèle opère 151 patients programmés en août, contre 118 dans la réalité et 236 sans absence. Un congé déclaré six semaines avant oblige à déplacer 103 patients déjà datés, contre 251 s'il est déclaré trois jours avant, et en reprogramme 27 à plus de 30 jours au lieu de 86 : *déclarer tôt* est la première règle.

Avec tous les aléas connus à l'avance à la fois (congés, maladies, indisponibilités de quelques heures, pannes et maintenances de salle, matériel manquant, lits fermés, annulations, patients non aptes, non venus), la gestion complète, qui reloge, décale, raccourcit et comble sans ajouter de demi-journée au chirurgien, déplace 204 patients au lieu de 237, en reprogramme 81 à plus de 30 jours au lieu de 100, et ramène le délai pour 90 % des patients de 102 à 94 jours (figure 22). Le comblement avance 66 patients de 13 jours en moyenne, et le relogement évite de fermer 8 vacations. Les patients à arbitrer, qui n'ont plus de date avant leur délai maximal, restent 42 : ils viennent surtout des congés, et sans heures de bloc en plus, la grille n'a pas la place de les reprendre à temps. C'est le prix du choix de ne pas ajouter de vacation : avec des demi-journées de rattrapage, ils tomberaient à 27, mais la variance des lits passerait de 5,2 à 6,4.

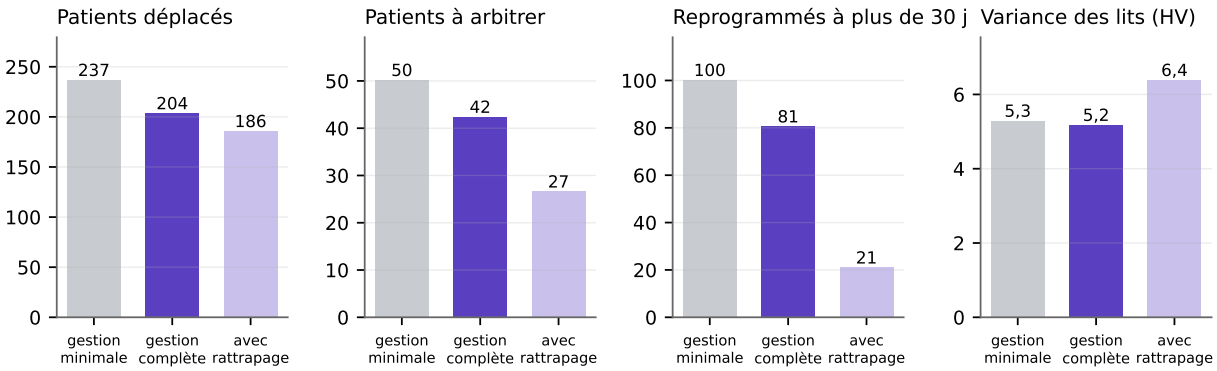


Figure 22 – Tous les aléas connus à l'avance, chaîne hybride, mai–décembre 2022 (cinq tirages). Gestion minimale : reprogrammation seule ; complète : relogement, décalage, raccourcissement et comblement, sans demi-journée de rattrapage ; avec rattrapage : pour mémoire.

À retenir

Chaque brique compte : la grille raccourcit les délais, la règle de date et les fantômes lissent les lits, la prévision des nuits limite un peu ce que coûte l'incertitude sur les séjours, et les agents servent 99 % des urgences à temps. Ces conclusions résistent à la cible choisie, à la réserve, à la surcharge et aux aléas connus à l'avance.

7.7 Limites

— La date de consultation est reconstruite à 30 jours avant l'opération.

— Les urgences sont repérées par le diagnostic, faute d'indicateur dans la base ; les fréquences des autres aléas sont des hypothèses.

— L'incertitude sur le séjour coûte encore cher (variance de 3,4 à 5,6) : le modèle d'apprentissage ne trouve le nombre exact de nuits que pour 70 % des patients.

— Les grilles sont construites par des recherches aléatoires : deux constructions donnent des variances qui diffèrent de quelques dixièmes, ce qui limite la finesse des comparaisons de réglages.

— La cible et la capacité en vacances sont calées sur les données, pas sur les effectifs réels de nuit.

— Le programmé n'occupe jamais plus de la moitié des 42 lits : le gain porte sur la régularité, pas sur la capacité. Le personnel d'anesthésie et infirmier n'est pas modélisé, et l'étude porte sur un seul établissement, essentiellement orthopédique.

8 Mise en œuvre à l'hôpital

Ce que cette partie établit. Une méthode qui marche en simulation doit encore pouvoir être utilisée par les équipes et respecter le cadre réglementaire.

8.1 L'interface

Pour que les équipes puissent utiliser la méthode, nous avons développé un site web. Il s'adresse au chirurgien, au secrétariat et au cadre de bloc, que l'on choisit par un sélecteur de rôle. Il ne contient que des données anonymisées ou fictives : les patients de démonstration sont marqués « démo ». Le site s'organise en cinq espaces, qui reprennent chacun une brique de la chaîne.

Prendre un rendez-vous opératoire. En consultation, le parcours se fait en quatre étapes. Le chirurgien saisit le patient, son diagnostic et l'acte prévu ; le site affiche la durée estimée par le modèle d'apprentissage, avec un intervalle. Le chirurgien donne alors son avis, obligatoire : opération plus longue, aussi longue ou plus courte que prévu. Le site propose ensuite les deux meilleures dates selon la règle hybride, avec leur effet sur la courbe des lits ; le rendez-vous est confirmé avec le patient et ne bouge plus (figure 23).

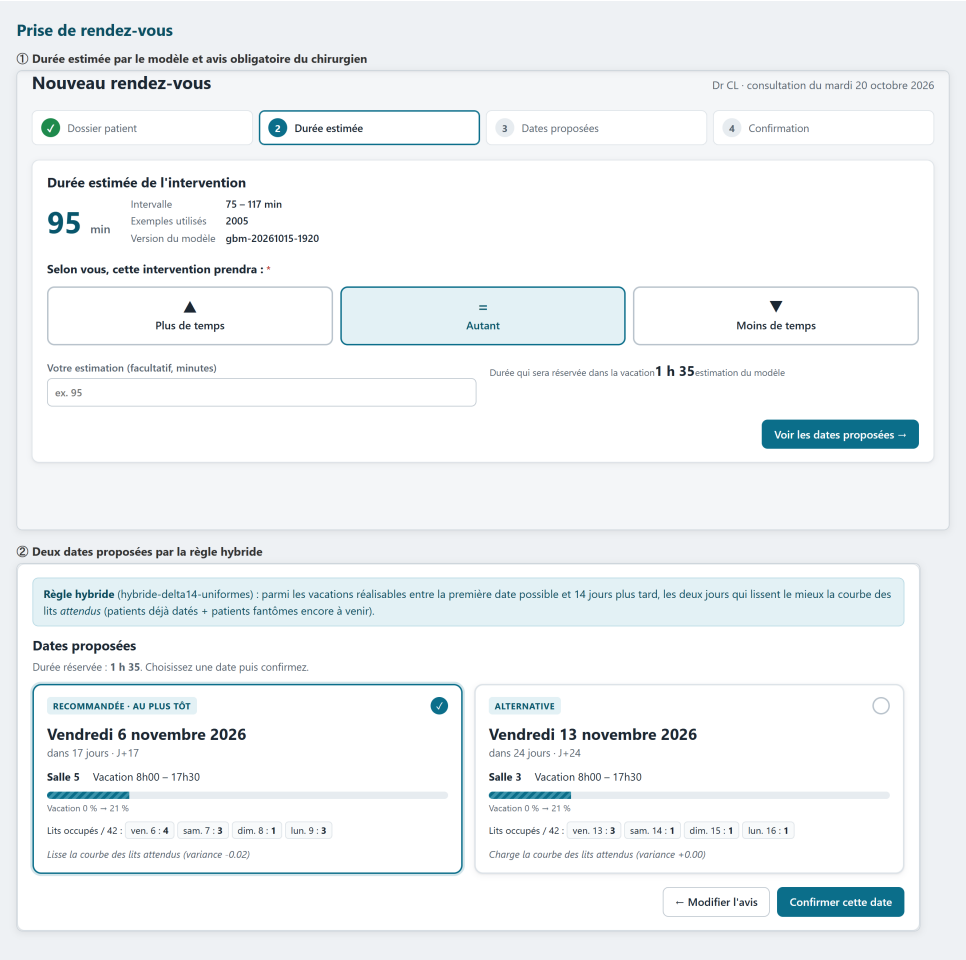


Figure 23 – Prise de rendez-vous : durée estimée par le modèle, avis du chirurgien, puis les deux dates proposées par la règle hybride avec leur effet sur les lits.

Consulter les plannings. Chaque chirurgien voit ses vacations et ses patients à la semaine ou au mois ; le cadre de bloc voit la grille des salles jour par jour, le remplissage de chaque vacation, marges comprises, la courbe des lits prévus chaque nuit et les admissions ambulatoires de chaque jour. Un bandeau signale les aléas en cours, et les vacations fermées sont hachurées (figure 24).

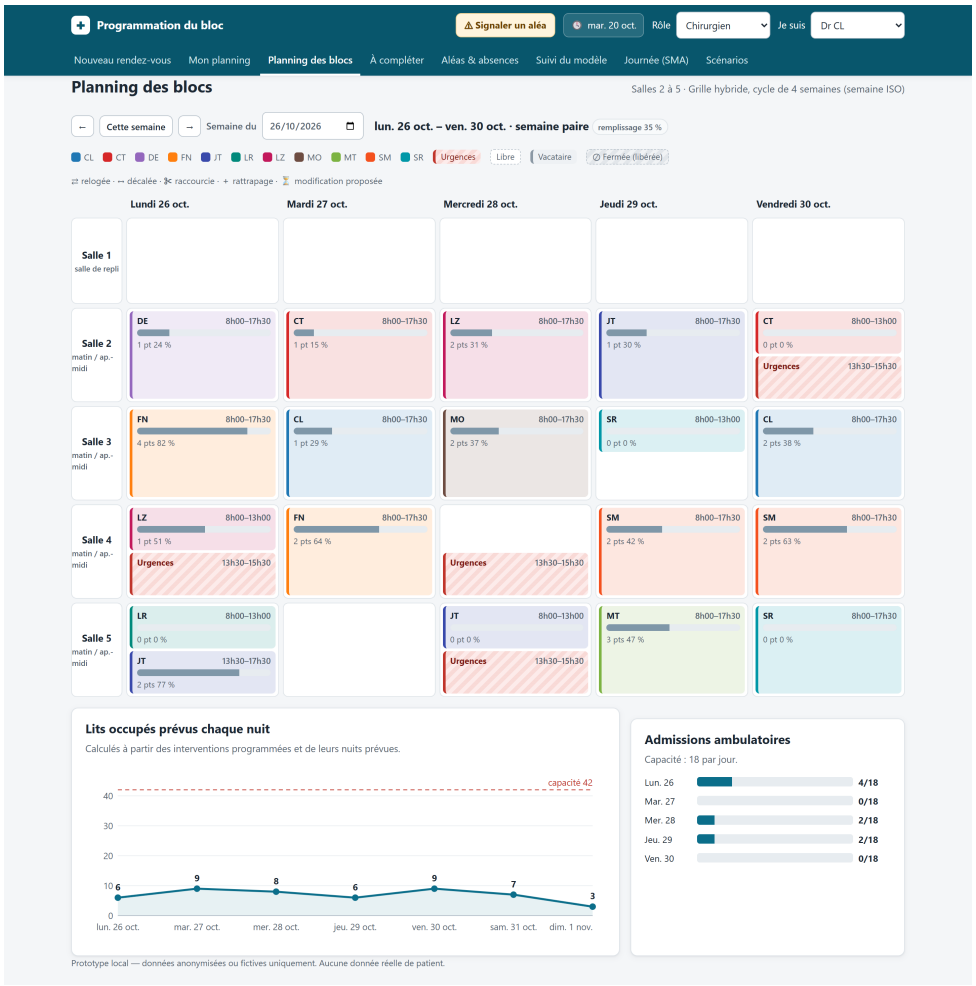


Figure 24 – Planning des blocs d'une semaine : une vacation par salle et par demi-journée, son remplissage, les créneaux d'urgence, la courbe des lits prévus et les admissions ambulatoires.

Gérer les aléas et les absences. Le bouton « Signaler un aléa », présent sur toutes les pages, ouvre le formulaire unique de la section 6.3 en trois étapes : quoi, quand et pour combien de temps, puis l'impact simulé avant enregistrement. Le moteur propose des actions : reloger, décaler, raccourcir ou fermer une vacation, et reprogrammer chaque patient touché avec deux dates au choix. Rien n'est appliqué sans validation humaine, et les actions sur les salles sont réservées au cadre de bloc (figure 25). Le cadre peut aussi, s'il le décide, ouvrir des demi-journées de rattrapage dans une salle libre ; cette option n'est pas celle retenue par défaut, puisqu'elle rend les lits moins réguliers (section 7.6). La page « Aléas et absences » rassemble les aléas en cours, les places libérées à proposer, les patients à prévenir et ceux à arbitrer.

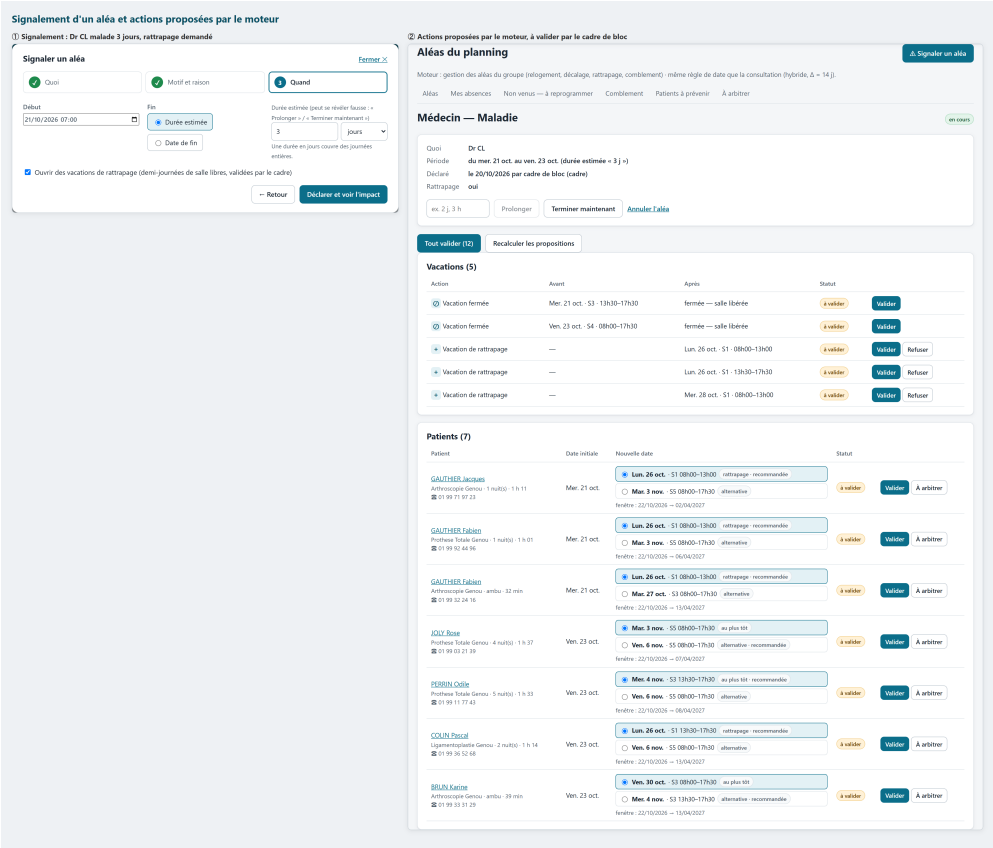


Figure 25 – Signalement d'un aléa (un chirurgien malade trois jours) et actions proposées par le moteur : vacations fermées, demi-journées de rattrapage demandées par le cadre, et deux dates pour chaque patient touché, toutes à valider.

Simuler et tester. Une page « Scénarios » rejoue les algorithmes du groupe sur l'état du bloc : comparer la règle hybride à la première date libre, voir ce que la règle de date voit à une date donnée, patients datés et fantômes, faire varier la fenêtre de tolérance, comparer une gestion minimale et une gestion complète des aléas, ou simuler une journée au bloc avec le système multi-agents.

Améliorer les prévisions. Après chaque opération, la durée réelle est saisie à partir des heures d'entrée et de sortie de salle. Elle devient un exemple pour réentraîner le modèle, et la page « Suivi du modèle » montre sa précision, ainsi que celle de l'avis des chirurgiens.

Architecture. Le serveur est écrit en Python (FastAPI, base SQLite, 55 routes), l'interface en React et TypeScript. Le code du groupe, chaîne hybride, système multi-agents et moteur d'aléas, est repris sans modification et appelé par une couche d'adaptation. Chaque brique, l'estimation des durées, les propositions de dates, le contrôle de faisabilité et les aléas, est définie par un contrat, ce qui permet d'en changer l'implémentation sans toucher au reste. L'application est couverte par 117 tests automatiques.

8.2 Le cadre réglementaire, et comment l'outil s'y conforme

Un logiciel qui touche à l'hôpital croise six textes : le règlement sur les dispositifs médicaux, le règlement européen sur l'intelligence artificielle, le RGPD et le secret médical, l'hébergement des données de santé, la politique de sécurité des systèmes d'information de santé et le cadre d'interopérabilité. Chacun impose des obligations lourdes. Plutôt que de les subir, nous avons conçu l'outil pour que chacune tombe hors de son champ ou se réduise au minimum : à chaque norme correspond un *levier* dans la conception du logiciel, qui permet de la *contourner* légalement (tableau 15).

Tableau 15 – Les six normes, le levier du logiciel et le contournement qu'il permet.

Norme	Ce qu'elle impose	Levier du logiciel	Contournement
MDR, marquage CE	certification de tout logiciel à finalité médicale	périmètre 100 % logistique : recherche opérationnelle sur des durées et des lits, pas de diagnostic	non qualifié de dispositif médical : hors du règlement (UE) 2017/745
AI Act	lourds audits pour les IA « à haut risque » : tri de patients, impact vital	apprentissage limité : il ne prédit que des temps d'occupation, et le chirurgien a le dernier mot	IA à risque minimal : pas de certification d'IA critique
RGPD et secret médical	interdiction de traiter des données de santé qui identifient une personne	filtre d'anonymisation : identifiants techniques opaques générés par l'hôpital	hors de l'article 9 : sans identité, plus de donnée personnelle de santé
Hébergement HDS	serveurs certifiés, coûteux	abstraction mathématique : la base ne garde que des blocs de temps et des numéros de salle	un hébergement en nuage classique et sécurisé suffit
PGSSI-S	audits pour qu'un logiciel tiers n'ouvre pas de brèche dans le réseau	isolement : aucune connexion directe, échange de fichiers plats par l'utilisateur	aucun risque de propagation : homologation simple
CI-SIS, INS	interopérabilité avec le Dossier Médical Partagé et l'identité nationale de santé	architecture autonome : ni compte rendu, ni prescription	pas d'échange clinique : ni INS, ni flux HL7

Dispositifs médicaux (MDR, marquage CE). Le règlement (UE) 2017/745 s'applique à tout logiciel destiné à une finalité médicale pour un patient : aider au diagnostic, choisir un traitement, surveiller un état de santé. Notre outil ne fait que de la recherche opérationnelle sur des durées, des vacations et des lits, et ne dit rien de l'état de santé du patient ; la décision d'opérer est prise avant lui. Il n'est donc pas un dispositif médical. Le contournement tient tant que l'usage revendiqué reste la logistique : une fonction qui classerait les patients par gravité le ferait tomber.

Intelligence artificielle (AI Act). Le règlement européen impose évaluation de conformité et audits aux systèmes d'IA « à haut risque », dont ceux qui trient des patients ou influent sur leur accès aux soins. Notre apprentissage ne prédit que des temps d'occupation, jamais une priorité ni un traitement, et il ne décide de rien : il propose deux dates, le chirurgien donne son avis et choisit, et chaque action sur un aléa est validée par un humain. Les urgences ne passent pas par l'apprentissage : leur classe U1 ou U2 vient d'une classification médicale publiée.

Données personnelles et secret médical (RGPD). L'article 9 du RGPD interdit en principe de traiter des données de santé qui permettent d'identifier une personne. Le logiciel ne reçoit donc jamais le nom, l'adresse ou le numéro de sécurité sociale du patient : l'hôpital lui transmet un identifiant opaque, par exemple OP-2026-892, dont il garde seul la correspondance. Deux conditions doivent être tenues : l'hôpital reste responsable de son traitement, et les variables transmises ne doivent pas permettre de retrouver un patient par recoupement. Dans notre prototype, l'estimation de la durée utilise l'âge, le diagnostic et l'acte : en déploiement, elle doit être faite du côté de l'hôpital, qui ne transmet à l'outil que la durée et les nuits prévues. Pendant le projet, seules des données anonymisées ou fictives ont été utilisées, et le fichier de l'hôpital n'a jamais été versé dans le dépôt de code.

Hébergement des données de santé (HDS). La base de l'outil ne garde qu'une abstraction mathématique du bloc : des blocs de temps, des numéros de salle, des chirurgiens, des lits par nuit et les identifiants opaques. Une donnée qui a perdu son caractère médical et ne permet plus d'identifier un patient n'est plus une donnée de santé au sens de cette obligation. C'est la même condition que pour le RGPD : tant que le diagnostic ou l'âge sont stockés, l'hébergement certifié reste nécessaire.

Sécurité des systèmes d'information (PGSSI-S). L'outil est isolé du réseau hospitalier : aucune connexion directe, aucune interface de programmation ouverte vers le système d'information. Les données circulent par un fichier plat, exporté du logiciel du bloc et déposé par un utilisateur, puis les plannings repartent de la même façon. Le prix est une manipulation de fichiers, à automatiser plus tard si l'hôpital l'accepte.

Interopérabilité (CI-SIS) et identité nationale de santé (INS). L'outil n'émet aucun compte rendu, ne gère aucune prescription et n'échange aucun document clinique. Il n'a donc ni à vérifier l'identité nationale de santé, ni à développer de flux HL7.

En résumé, l'outil reste un outil de logistique : il ne voit ni diagnostic, ni identité, ni réseau de l'hôpital, et la décision reste toujours humaine. Ces contournements sont à confirmer avec le délégué à la protection des données et le responsable de la sécurité de l'établissement avant tout déploiement.

9 Conclusion

Nous sommes partis d'une question : peut-on coordonner le bloc, les lits et l'ambulatoire sans ajouter d'heures de bloc ? Les données ont montré ce qu'il fallait lisser, les nuits de semaine, et ce qui était prévisible, les urgences. Le problème a été découpé en trois niveaux, et ce qui manque à la consultation a été prévu : la durée et le séjour par apprentissage, la demande à venir par des patients fantômes. Les trois études du groupe ont montré chacune un point fort et son prix : la grille du tabou lisse les lits mais allonge les délais, le génétique raccourcit les délais avec plus d'heures de bloc, le recuit occupe le mieux le bloc sans lisser les lits. La chaîne hybride garde chaque bon choix et corrige son prix. À heures de bloc constantes, elle divise par 3,4 la variance des lits des nuits de semaine par rapport à la pratique simulée, ramène le pic de 21 à 17 lits et le délai qui couvre 90 % des patients de 115 à 51 jours, sans patient sans date. Lorsque le séjour n'est plus supposé connu, le lissage se dégrade nettement, et la prévision des nuits par apprentissage n'en récupère qu'une petite partie : c'est la principale marge de progrès. Le jour de l'opération, le système multi-agents opère 99 % des urgences dans leur délai, contre 87 % sans agents, et divise leur attente par 3,6, au prix de quelques reports.

Des choix au service de l'établissement. Les valeurs retenues dans ce rapport sont des *prises de position* de notre étude, faites pour un compromis raisonnable sur les données de cet établissement. Plusieurs arbitrent entre deux objectifs que chaque hôpital ou clinique peut pondérer à sa manière : un établissement qui veut avant tout raccourcir l'attente n'a pas les mêmes priorités qu'un service qui manque de personnel de nuit le week-end. L'outil laisse ces paramètres au choix du service (tableau 16).

Tableau 16 – Les paramètres que l'établissement peut régler selon son fonctionnement, et ce que l'on a mesuré.

Paramètre	Notre choix	Ce qu'il arbitre, et ce que l'on a mesuré
Fenêtre de tolérance	14 jours	lissage contre délai : 7 jours donnent une variance de 6,1 et 19 jours de délai médian, 14 jours 3,4 et 22 jours, 28 jours 2,5 et 29 jours
Date retenue parmi les deux proposées	la plus proche	la meilleure pour les lits lisserait encore (2,7 au lieu de 3,4), pour 2 à 3 jours d'attente de plus
Cible du week-end et des vacances	70 % et 65 % de la semaine	à régler selon le personnel du week-end et des vacances ; sans cible, le week-end remonte à 81 % de la semaine ; la régularité de la semaine en dépend peu
Capacité en vacances, ponts et fériés	12 lits	plafond fixé par les effectifs de nuit réellement présents
Réserve pour les urgences	5 % du temps, 2 lits, 2 admissions	sans agents, 15 % servent mieux les urgences (94 % à temps) mais doublent le délai médian ; avec agents, la réserve compte peu
Volume de chaque chirurgien	75 à 150 % de l'actuel	liberté laissée à la grille pour suivre la demande, contre stabilité des habitudes
Délais avant l'opération	7 jours à 6 mois	délai minimal de préparation et délai maximal accepté
Prévision des durées	médiane de l'acte	l'apprentissage raccourcit le délai médian (18 jours au lieu de 22) mais lisse moins les lits (7,3 au lieu de 5,6)
Retard accepté le jour J	60 minutes	au-delà, le dernier patient est reporté : moins de dépassement, plus de reports
Rattrapage d'une absence	non	des demi-journées de rattrapage feraient passer les patients à arbitrer de 42 à 27, mais la variance des lits de 5,2 à 6,4

Plusieurs prolongements sont possibles :

— tenir compte de l'incertitude des séjours dans la règle de date, par exemple en jugeant une date sur la loi des nuits plutôt que sur leur espérance ;

— apprendre les fantômes d'urgence sur les années les plus récentes ;

— dimensionner les créneaux d'urgence avec le système multi-agents, plutôt qu'en heures fixes ;

— intégrer le personnel d'anesthésie et infirmier comme quatrième ressource ;

— mener un essai en conditions réelles avec l'interface.

Références

[1] Brecht Cardoen, Erik Demeulemeester, and Jeroen Beliën. Operating room planning and scheduling : A literature review. *European Journal of Operational Research*, 201(3) :921–932, 2010. doi : 10.1016/j.ejor.2009.04.011.

[2] Jeroen Beliën and Erik Demeulemeester. Building cyclic master surgery schedules with leveled resulting bed occupancy. *European Journal of Operational Research*, 176(2) :1185–1204, 2007. doi : 10.1016/j.ejor.2005.06.063.

[3] Andreas Fügener, Erwin W. Hans, Rainer Kolisch, Nikky Kortbeek, and Peter T. Vanberkel. Master surgery scheduling with consideration of multiple downstream units. *European Journal of Operational Research*, 239(1) :227–236, 2014. doi : 10.1016/j.ejor.2014.05.009.

[4] Jonathan Patrick, Martin L. Puterman, and Maurice Queyranne. Dynamic multipriority patient scheduling for a diagnostic resource. *Operations Research*, 56(6) :1507–1525, 2008. doi : 10.1287/opre.1080.0590.

[5] Scott Kirkpatrick, C. Daniel Gelatt, and Mario P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598) :671–680, 1983. doi : 10.1126/science.220.4598.671.

[6] Fred Glover. Future paths for integer programming and links to artificial intelligence. *Computers & Operations Research*, 13(5) :533–549, 1986. doi : 10.1016/0305-0548(86)90048-1.

[7] John H. Holland. *Adaptation in Natural and Artificial Systems.* University of Michigan Press, Ann Arbor, 1975.

[8] Inês Marques, M. Eugénia Captivo, and Margarida Vaz Pato. Scheduling elective surgeries in a Portuguese hospital using a genetic heuristic. *Operations Research for Health Care*, 3(2) :59–72, 2014. doi : 10.1016/j.orhc.2013.12.001.

[9] Torsten O. Paulussen, Nicholas R. Jennings, Keith S. Decker, and Armin Heinzl. Distributed patient scheduling in hospitals. In *Proceedings of the 18th International Joint Conference on Artificial Intelligence (IJCAI-03)*, pages 1224–1232, 2003.

[10] Matthew A. Bartek, Rajeev C. Saxena, Stuart Solomon, Christine T. Fong, Lakshmana D. Behara, Ravitheja Venigandla, Kalyani Velagapudi, John D. Lang, and Bala G. Nair. Improving operating room efficiency : Machine learning approach to predict case-time duration. *Journal of the American College of Surgeons*, 229(4) :346–354.e3, 2019. doi : 10.1016/j.jamcollsurg.2019.05.029.